Обработка и исполнение запросов в СУБД (Лекция 8)

Колоночные СУБД в оперативной памяти

v6

Георгий Чернышев

Высшая Школа Экономики

chernishev@gmail.com

21 октября 2020 г.

План

Рассмотрим систему MonetDB — колоночную систему в оперативной памяти.

- MonetDB, ее принципы устройства, планы запросов
- Аппаратные основания для появления MonetDB
- MonetDB как исследовательская платформа:
  - Cache-conscious соединение
  - Database cracking
  - Recycler
- Буфер-менеджер "на пальцах"
- MonetDB/X100

MonetDB — колоночная СУБД в памяти

Вкратце из статей, например
[Boncz and Kersten, 1999, Boncz et al., 2008]:

- Данные представлены в виде BAT структур (Binary Association Table): набор пар (*key*, *value*);
- Над BAT есть своя алгебра: каждый оператор работает над одним или несколькими BAT, возвращает BAT;
- Не Volcano, а operator-at-a-time model;
- Каждый оператор очень простой. Фактически, реализация операций над массивом;
- Все данные в памяти, mmap-ом отображаются на диск, если виртуальной памяти не хватит, используем за-mmap-леную дисковую, есть подсистема (это вместо буфер-менеджера).

Этот подход позволяет очень эффективно использовать процессор и оперативную память.

Простой пример

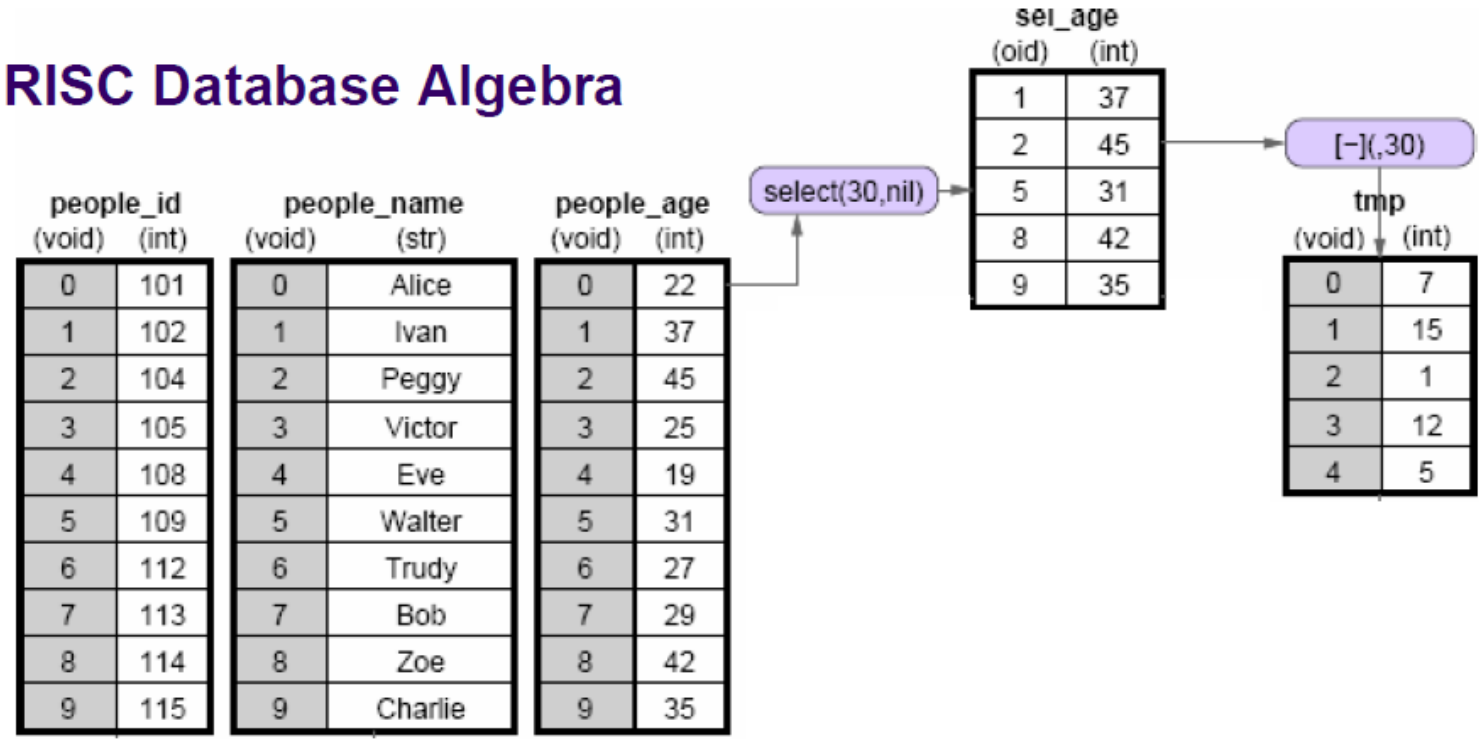


```
SELECT   id, name, (age-30)*50 as bonus
FROM     people
WHERE    age > 30
```

1

[1] Изображение взято из [Harizopoulos et al., 2009]

Пример посложнее (смотрите в план в pdf)

SQL example query

```
SELECT    item.id AS id,
          item.price*item.tax AS total
WHERE     order.id = item.order AND
          order.discount BETWEEN 0.00 AND 0.06
ORDER BY total,id
```

MIL translation *(annotated below)*

```
ORD_NIL := select(order_discount,"between",0.0,0.06)
1  a bat[oid,oid], head column with selected order-oids, nils in tail
IDS_NIL := join(order_id.reverse,ORD_NIL,"=")
2  creates a bat[oid,oid] with selected order-IDs in head, nil tail
ITM_NIL := join(item_order,IDS_NIL,"=")
3  creates a bat[oid,oid] with selected item-IDs in head, nil tail
UNQ_ITM := mark(ITM_NIL,oid(0)).reverse
4  creates a bat[oid,oid] fresh oids in head, selected item-IDs in tail
UNQ_PRI := join(UNQ_ITM,item_price,"=")
5  creates a bat[oid,flt] with selected item-IDs and their prices
UNQ_TAX := join(UNQ_ITM,item_tax,"=")
6  creates a bat[oid,flt] with selected item-IDs and their taxes
UNQ_TOT := [*](UNQ_PRI,UNQ_TAX)
           creates a bat[oid,flt] with selected item-IDs and totals
table("2,1",UNQ_ITM,UNQ_TOT)
           prints a 2-column table with item IDs and totals, with major
           ordering on the second column, and secondary ordering on the first
```

Fig. 4. A simple SQL query and a MIL translation

2

[2] Изображение взято из [Boncz and Kersten, 1999]

Про “железо” “на пальцах” I

Elements:

- Storage
  - CPU caches L1/L2/L3
- Registers
- Execution Unit(s)
  - Pipelined
  - SIMD

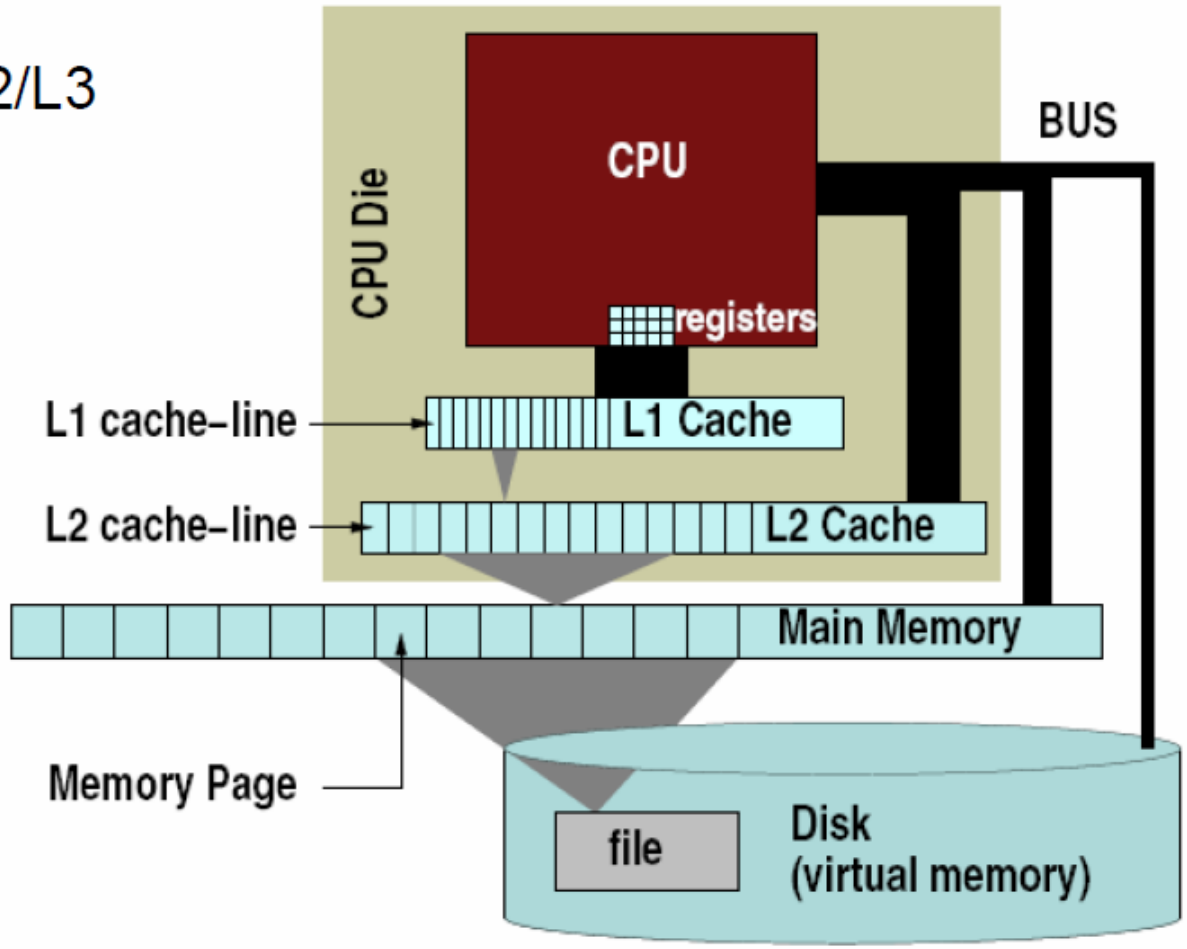

3

[3] Изображение взято из [Harizopoulos et al., 2009]

Про “железо” “на пальцах” II (SIMD)

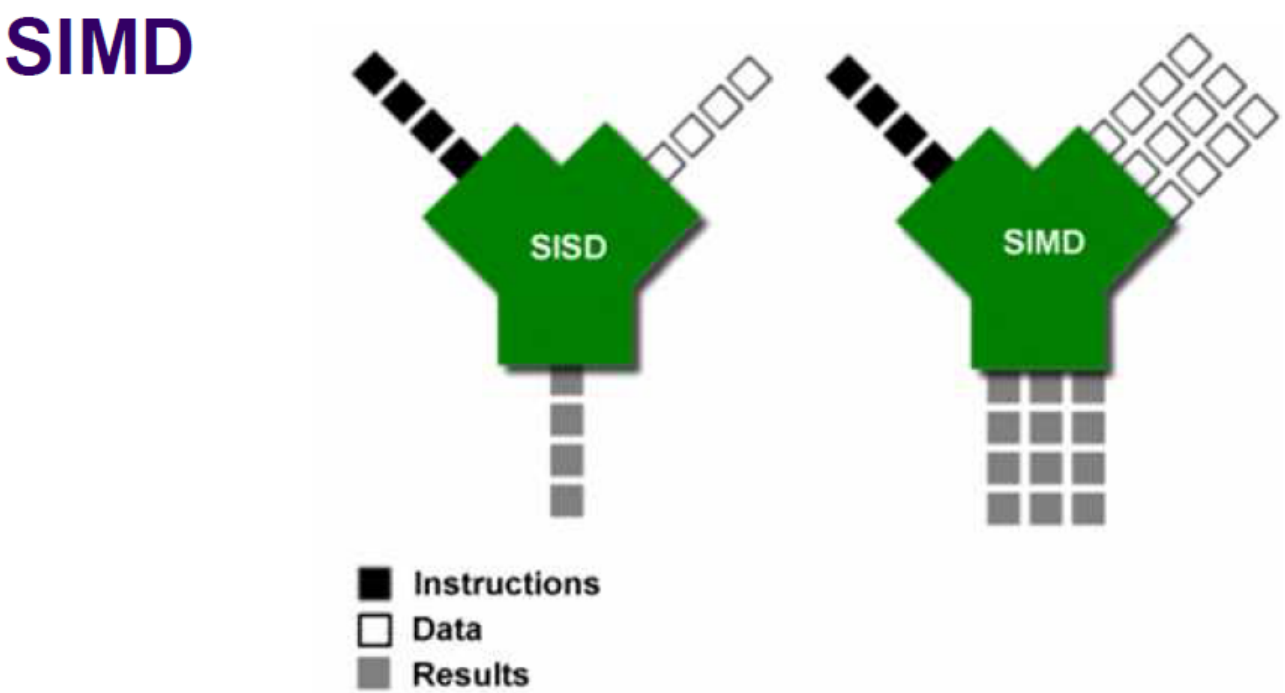

- Single Instruction Multiple Data
  - Same operation applied on a vector of values
  - MMX: 64 bits, SSE: 128bits, AVX: 256bits
  - SSE, e.g. multiply 8 short integers [4]

[4] Изображение взято из [Harizopoulos et al., 2009]

Про “железо” “на пальцах” III (эволюция процессоров)

Microprocessor	16-bit address/ bus, microcoded	32-bit address/ bus, microcoded	5-stage pipeline, on-chip I & D caches, FPU	2-way superscalar, 64-bit bus	Out-of-order 3-way superscalar	Out-of-order superpipelined, on-chip L2 cache	Multicore OOO 4-way on chip L3 cache, Turbo
Product	Intel 80286	Intel 80386	Intel 80486	Intel Pentium	Intel Pentium Pro	Intel Pentium 4	Intel Core i7
Year	1982	1985	1989	1993	1997	2001	2010
Die size (mm^2)	47	43	81	90	308	217	240
Transistors	134,000	275,000	1,200,000	3,100,000	5,500,000	42,000,000	1,170,000,000
Processors/chip	1	1	1	1	1	1	4
Pins	68	132	168	273	387	423	1366
Latency (clocks)	6	5	5	5	10	22	14
Bus width (bits)	16	32	32	64	64	64	196
Clock rate (MHz)	12.5	16	25	66	200	1500	3333
Bandwidth (MIPS)	2	6	25	132	600	4500	50,000
Latency (ns)	320	313	200	76	50	15	4
Memory module	DRAM	Page mode DRAM	Fast page mode DRAM	Fast page mode DRAM	Synchronous DRAM	Double data rate SDRAM	DDR3 SDRAM
Module width (bits)	16	16	32	64	64	64	64
Year	1980	1983	1986	1993	1997	2000	2010
Mbits/DRAM chip	0.06	0.25	1	16	64	256	2048
Die size (mm^2)	35	45	70	130	170	204	50
Pins/DRAM chip	16	16	18	20	54	66	134
Bandwidth (MBytes/s)	13	40	160	267	640	1600	16,000
Latency (ns)	225	170	125	75	62	52	37

5

[5] Изображение взято из [Hennessy and Patterson, 2011]

Про “железо” “на пальцах” IV (25 лет эволюции RAM)

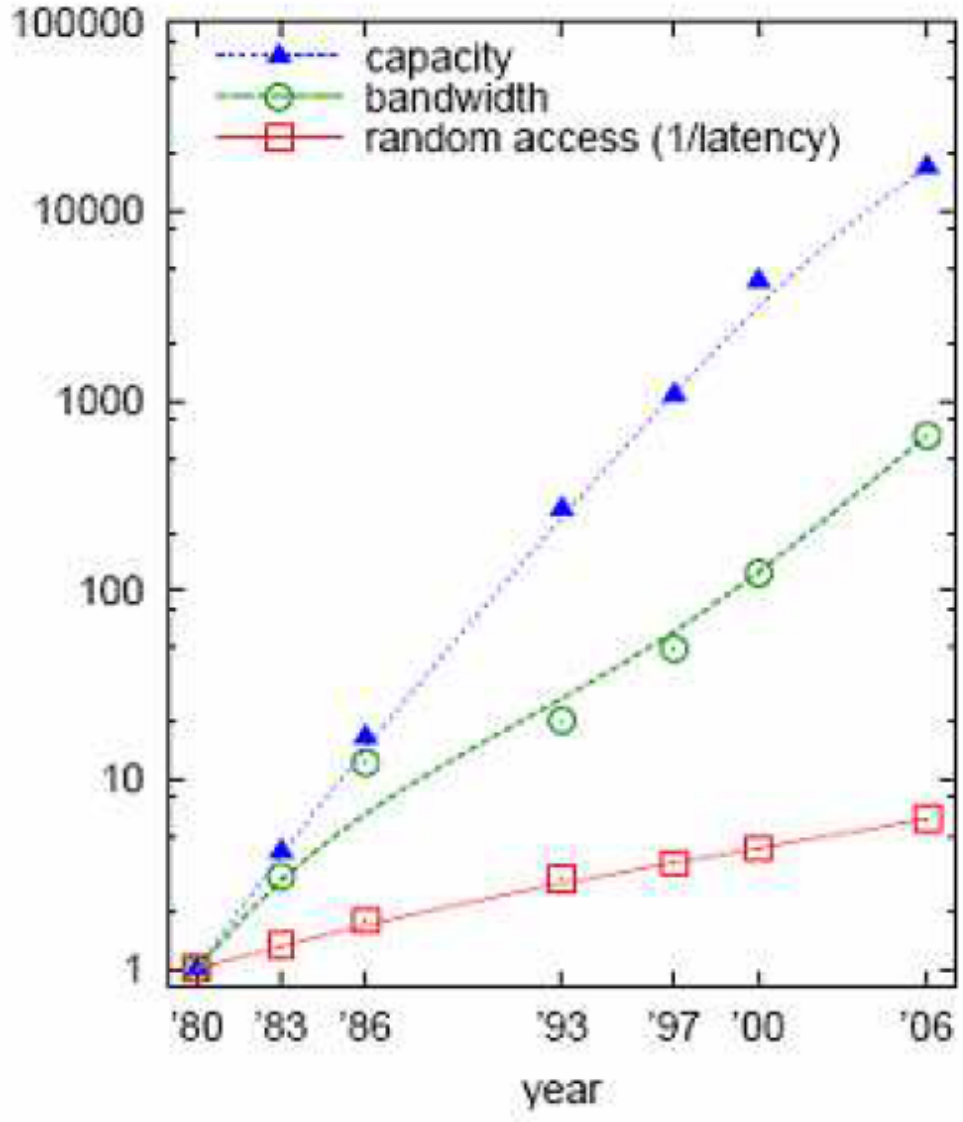

[6]

[6] Изображение взято из [Harizopoulos et al., 2009]

Про “железо” “на пальцах” V (иерархия носителей)

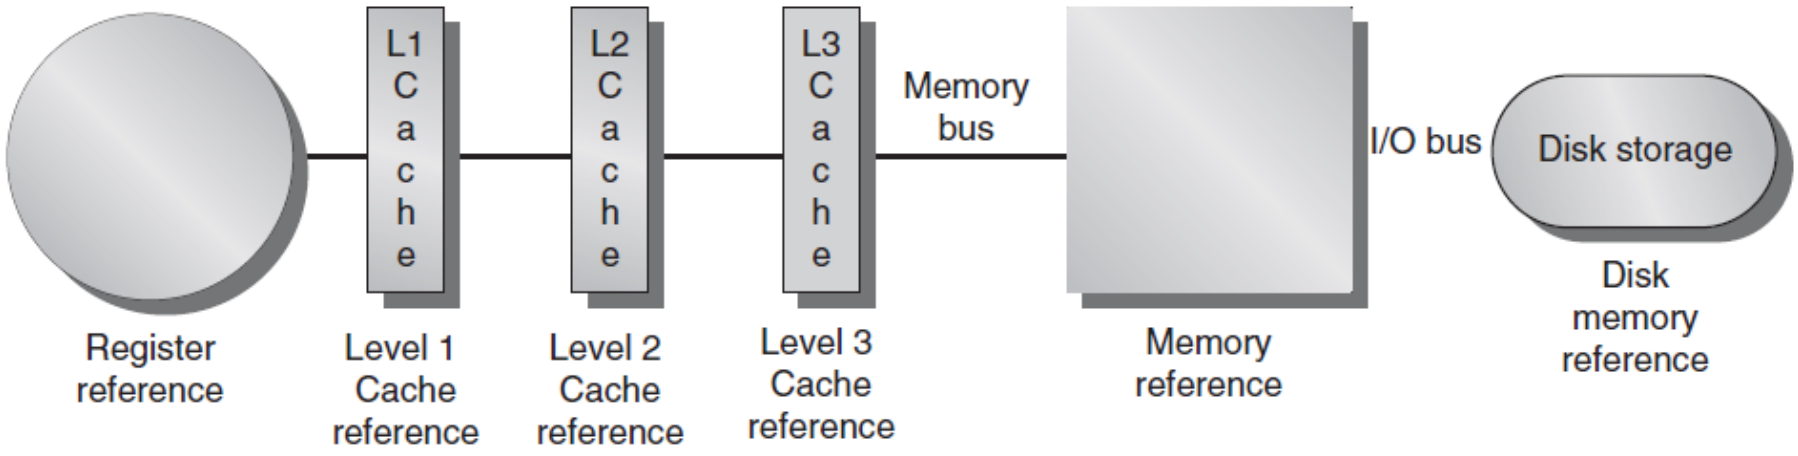

(a) Memory hierarchy for server

7

[7] Изображение взято из [Hennessy and Patterson, 2011]

Про “железо” “на пальцах” VI (стоимость операций)

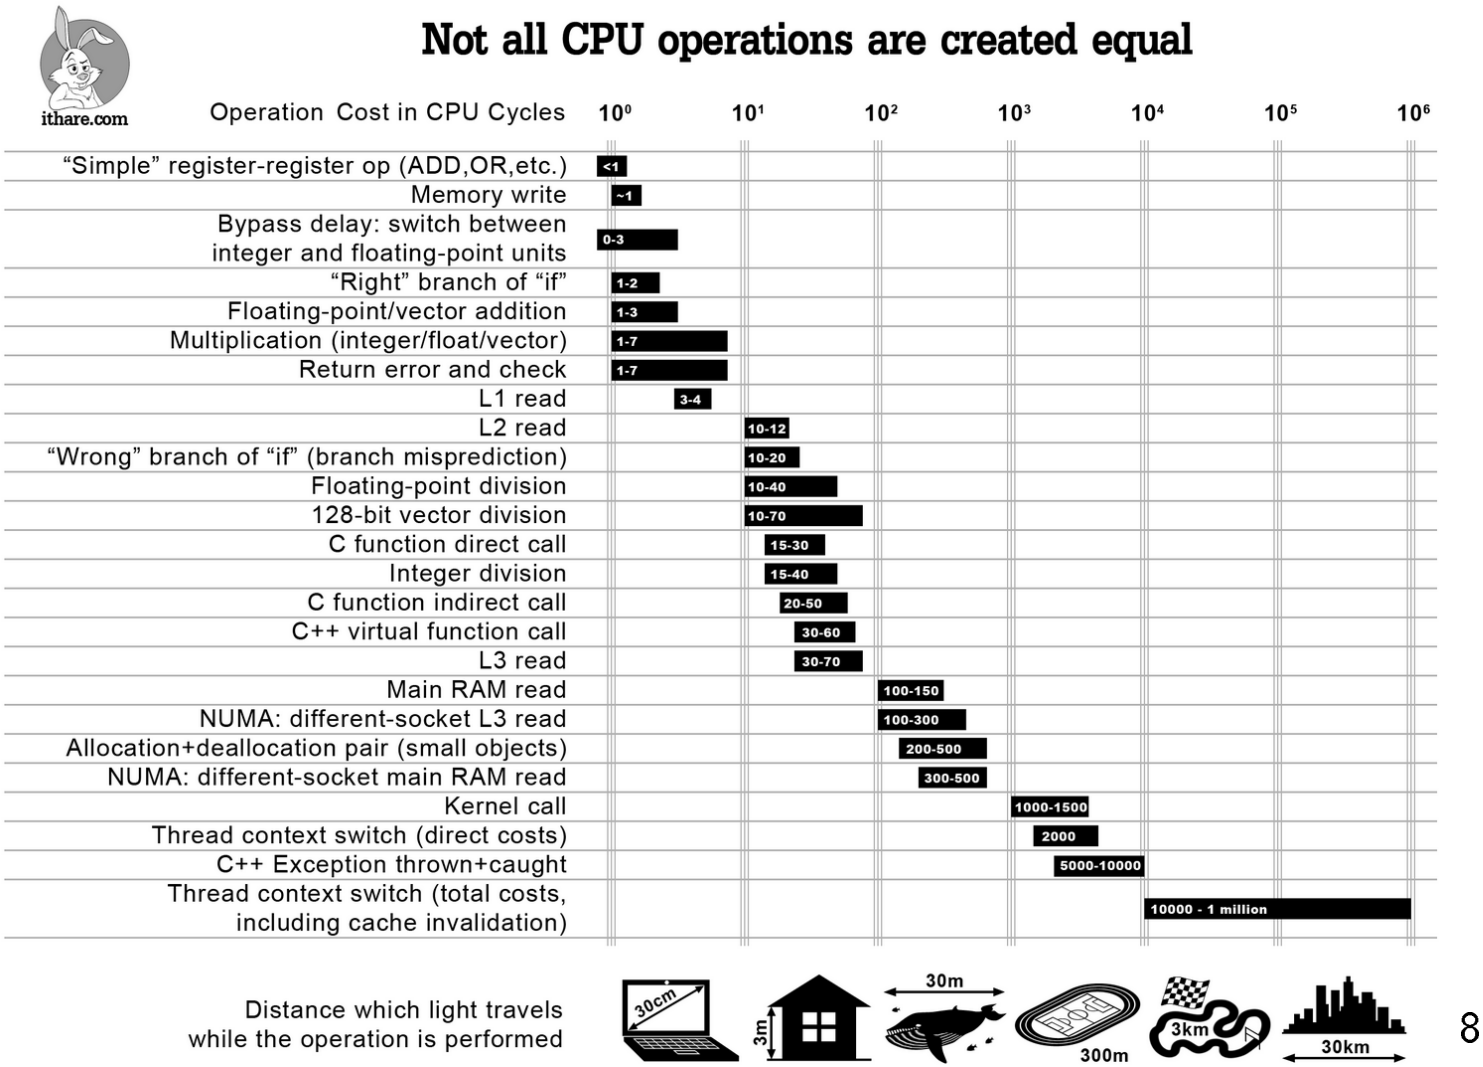

[8]

[8] Изображение взято из http://ithare.com/wp-content/uploads/part101_infographics_v07.png

О кеш-памяти

Бывает:

- Кеш данных — хранит данные, которыми оперирует программа,
- Кеш инструкций — хранит саму программу.

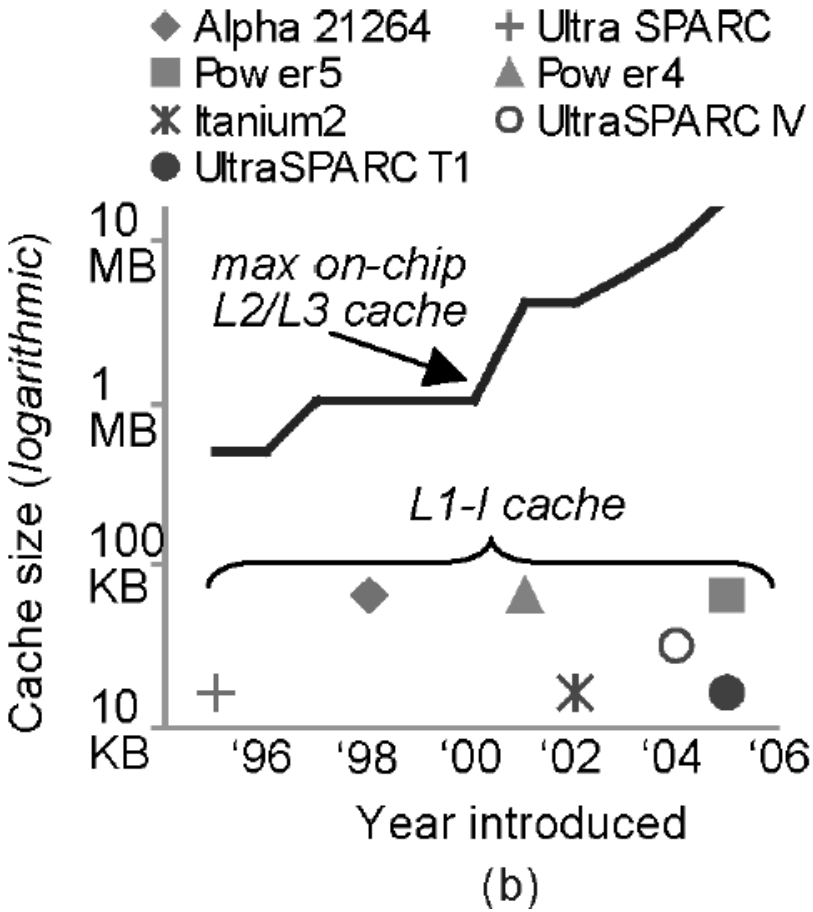

[9]

[9] Изображение взято из [Harizopoulos and Ailamaki, 2006]

Как выглядит код в кеш-памяти

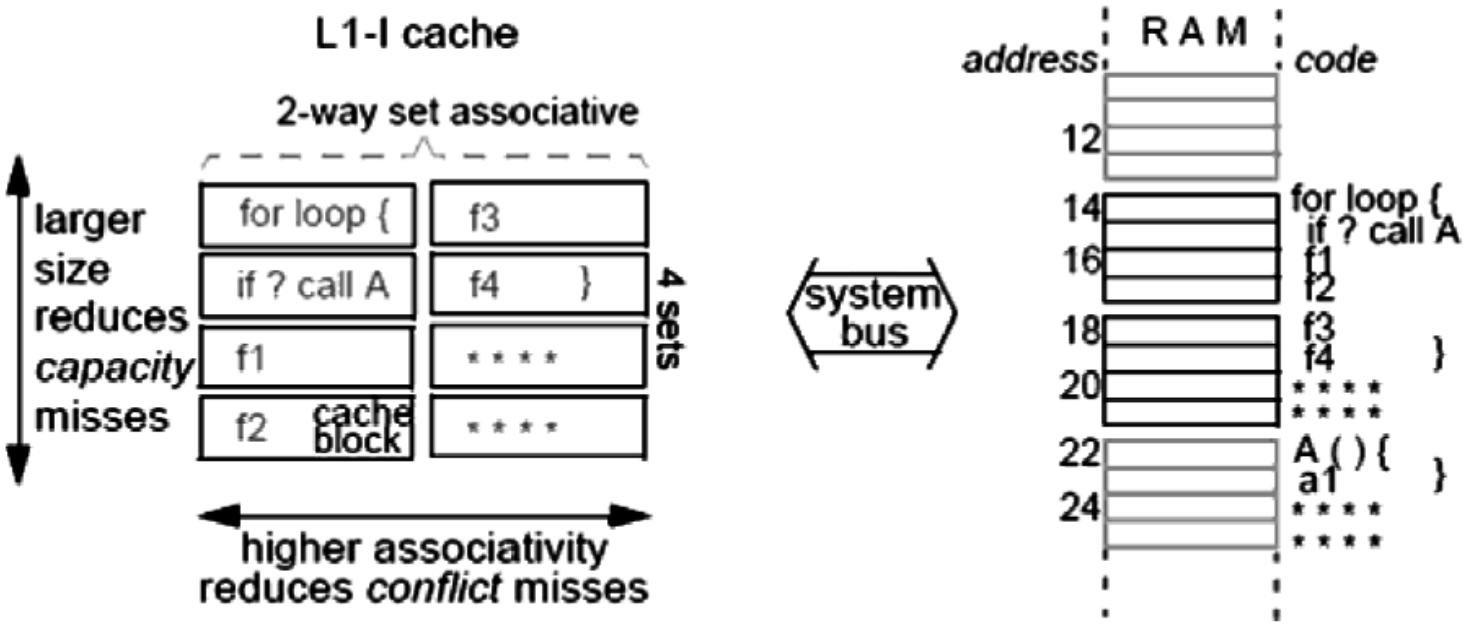

Fig. 1. Example of a two-way set associative, four-set (eight cache blocks) L1-I cache. Code stored in RAM maps to one set of cache blocks and is stored to any of the two blocks in that set. For simplicity, we omit L2/L3 caches. In this example, the *for-loop* code fits in the cache only if procedure A is never called. In that case, repeated executions of the code will always hit in the L1-I cache. Larger code (more than eight blocks) would result in *capacity* misses. On the other hand, frequent calls to A would result to *conflict* misses because A's code would replace code lines f3 and f4 needed in the next iteration.

10

[10] Изображение взято из [Harizopoulos and Ailamaki, 2006]

Кеш-память и цифры

- L1 кеш 8-64KB (и данные, и инструкции), больше не будет:
  - придется снижать частоту, температура
- В OLTP код занимает 556 KB, смотри ссылку из [Harizopoulos and Ailamaki, 2006].

То есть, для достижения хорошей производительности надо писать “правильный” код.

Про “железо” “на пальцах” VII: конвейер

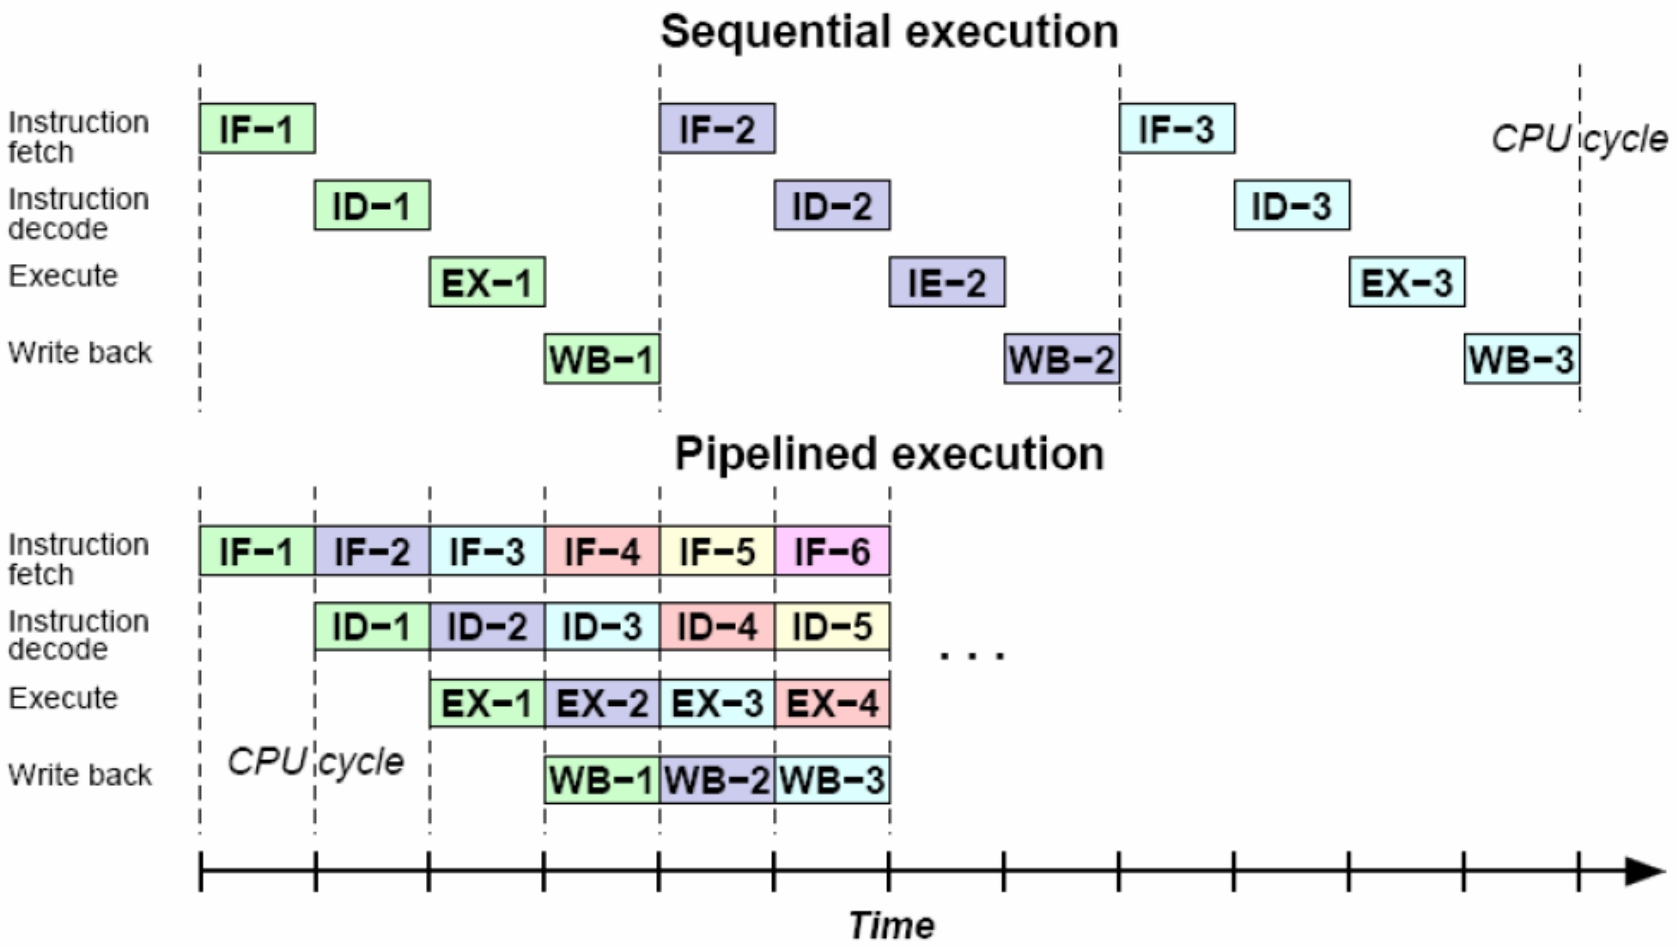

11

Кому непонятно, читайте `https://en.wikipedia.org/wiki/Instruction_pipelining`.

[11] Изображение взято из [Harizopoulos et al., 2009]

Про “железо” “на пальцах” VIII: проблемы выполнения

- Data hazards
  - Dependencies between instructions
  - L1 data cache misses
- Control Hazards
  - Branch mispredictions
  - Computed branches (late binding)
  - L1 instruction cache misses

Result: bubbles in the pipeline

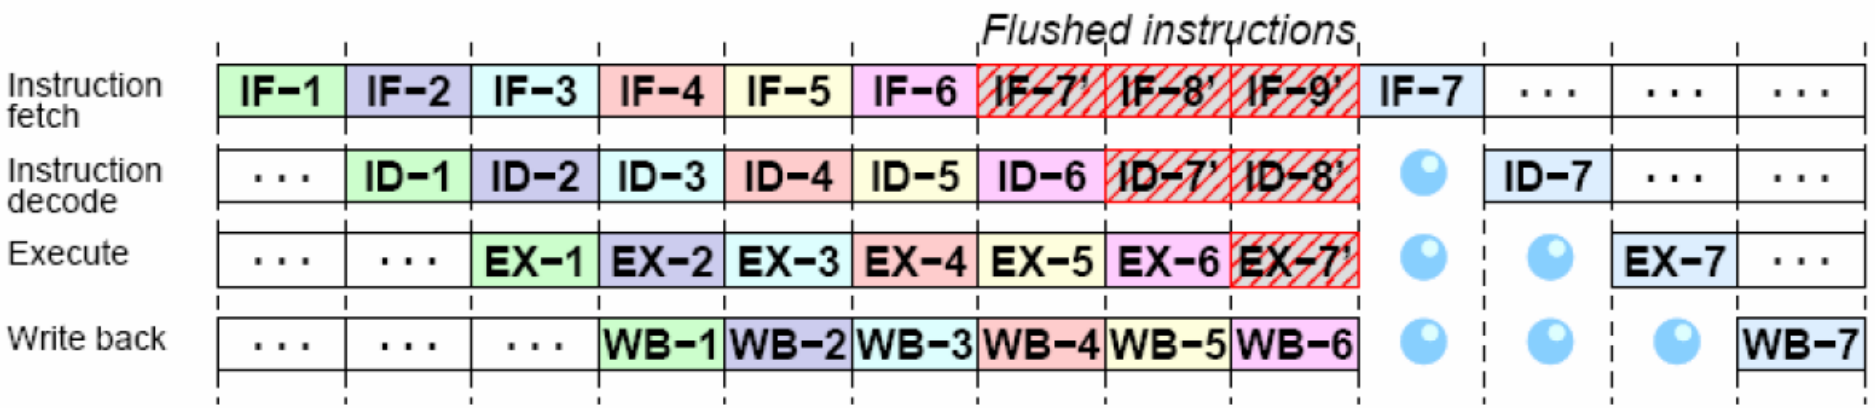

Out-of-order execution addresses data hazards

- control hazards typically more expensive

12

[12] Изображение взято из [Harizopoulos et al., 2009]

Как себя ведет процессор под нагрузкой (итераторами) I

- DB workload execution on a modern computer

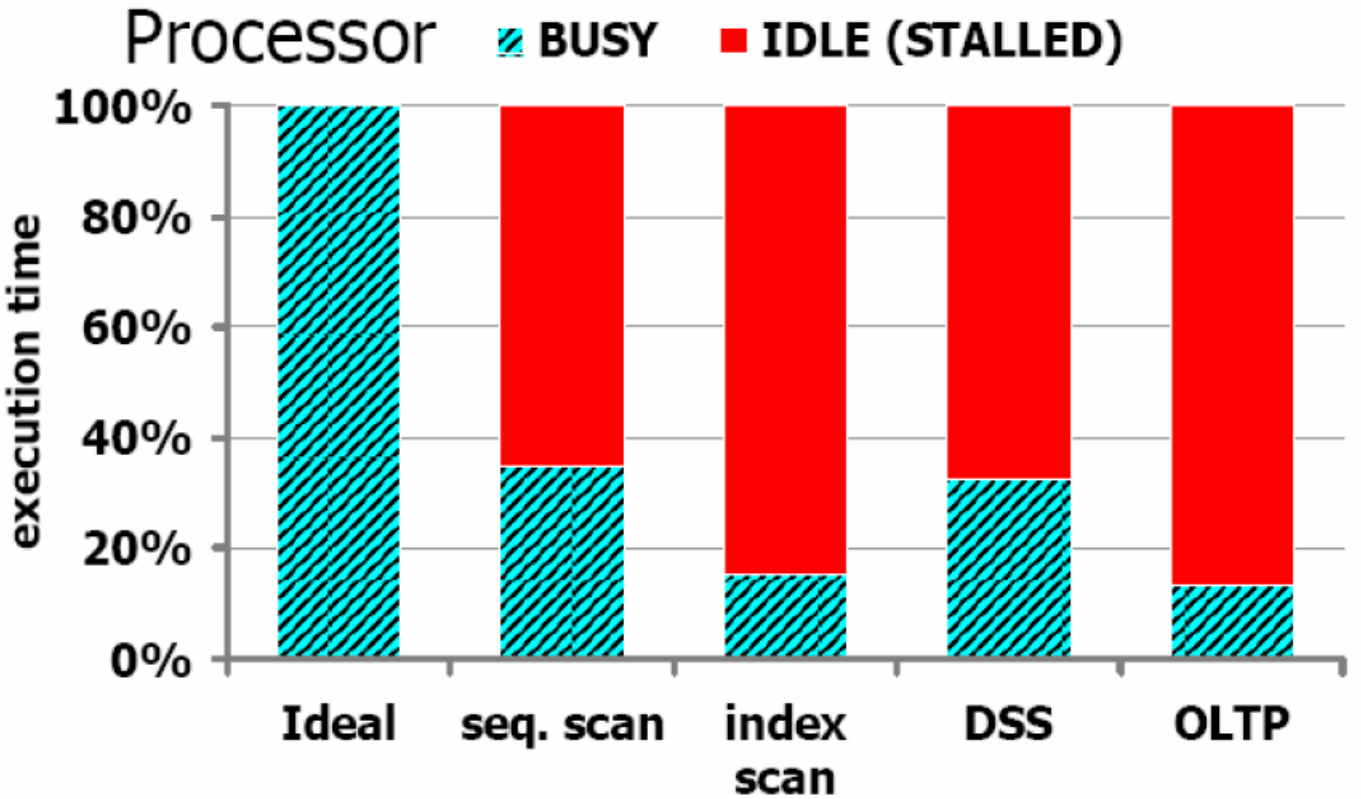

"DBMSs On A Modern Processor: Where Does Time Go? "
Ailamaki, DeWitt, Hill, Wood, VLDB'99

13

[13] Изображение взято из [Harizopoulos et al., 2009]

Как себя ведет процессор под нагрузкой (итераторами) II

Вкратце из статьи [Boncz et al., 2005]:

- TPC-H 1GB, Q1 (выборки, агрегация)
- Итог:
  - C program: 0.2s
  - MySQL: 26.2s
  - DBMS “X”: 28.1s

Как такой (MonetDB) подход помогает?

Вот так [Boncz et al., 2008, Harizopoulos et al., 2009]:

- "Хороший" с точки зрения CPU код:
  - Меньше зависимостям по данным;
  - Меньше зависимостям по управлению;
  - Можно автоматически генерировать SIMD-код.

- Один цикл для целой колонки:
  - Отказ от работы на уровне записи;
  - Массивы позволяют переходить по смещениям;
  - Лучше ситуация с кешем инструкций.

```
1 {
2   for(i=0; i<n; i++)
3     res[i] = col[i] - val;
4 }
```

Итог: Monet около 4s.

Проблемы

Материализация результата
[Boncz et al., 2008, Harizopoulos et al., 2009]:

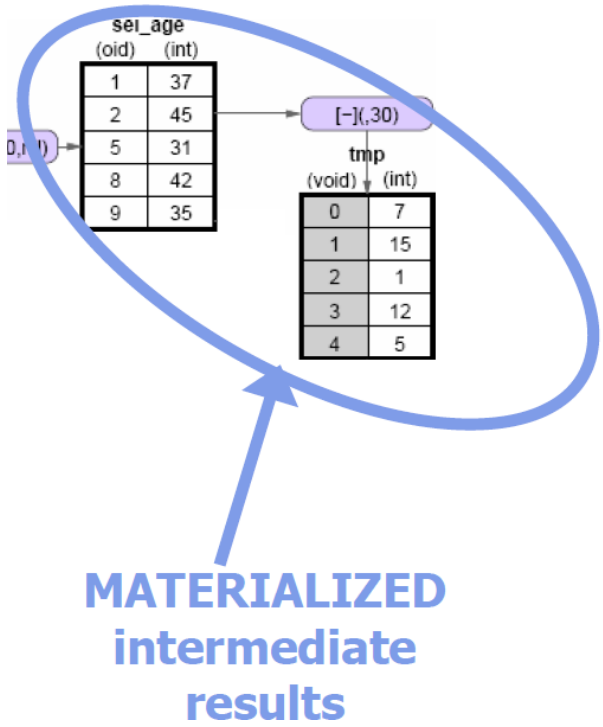

14

Памяти просто может не хватить, не будет масштабируемости.

[14] Изображение взято из [Harizopoulos et al., 2009]

Ниша: исследовательская платформа I

Figure 2: MonetDB: a BAT algebra machine.

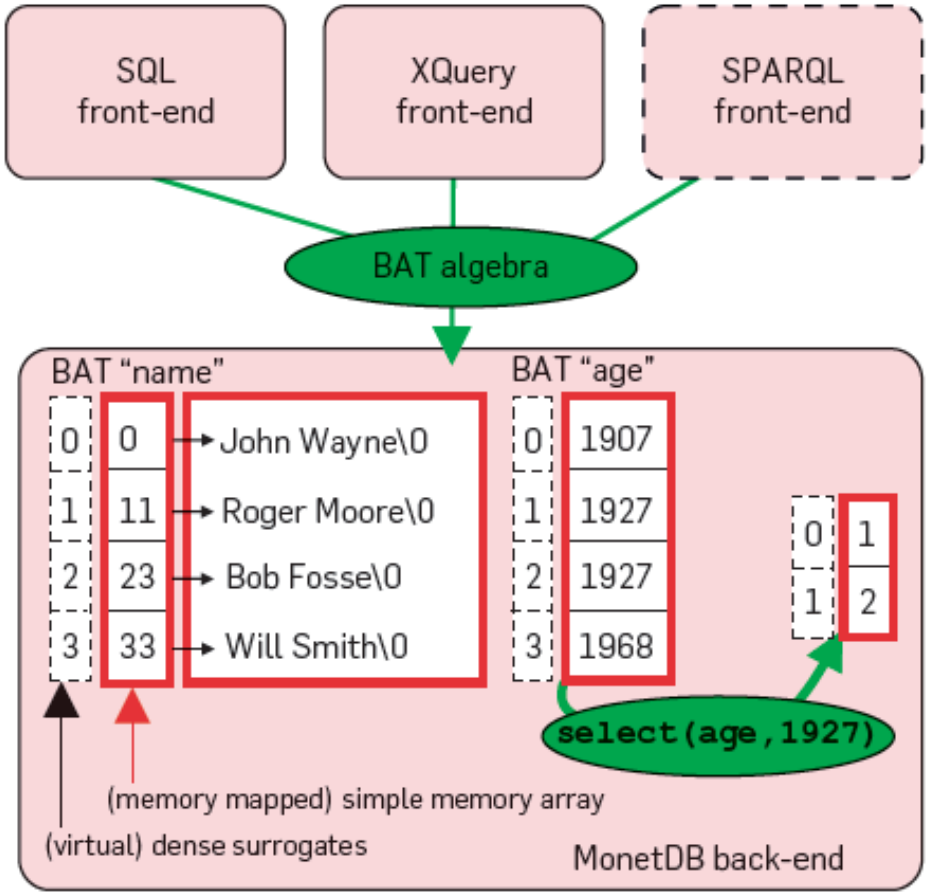

15

[15] Изображение взято из [Harizopoulos et al., 2009]

Ниша: исследовательская платформа II

- Cache-Conscious Joins
  - Cost Models, Radix-cluster Radix-decluster

•“Database Architecture Optimized for the New Bottleneck: Memory Access” VLDB’99
•“Generic Database Cost Models for Hierarchical Memory Systems”, VLDB’02 (all Manegold, Boncz, Kersten)
•“Cache-Conscious Radix-Decluster Projections”, Manegold, Boncz, Nes, VLDB’04

- MonetDB/XQuery:
  - structural joins exploiting positional column access

“MonetDB/XQuery: a fast XQuery processor powered by a relational engine” Boncz, Grust, vanKeulen, Rittinger, Teubner, SIGMOD’06

- Cracking:
  - on-the-fly automatic indexing without workload knowledge

“Database Cracking”, CIDR’07
“Updating a cracked database “, SIGMOD’07
“Self-organizing tuple reconstruction in column-stores“, SIGMOD’09 (all Idreos, Manegold, Kersten)

- Recycling:
  - using materialized intermediates

“An architecture for recycling intermediates in a column-store”, Ivanova, Kersten, Nes, Goncalves, SIGMOD’09

- Run-time Query Optimization:
  - correlation-aware run-time optimization without cost model

“ROX: run-time optimization of XQueries”, Abdelkader, Boncz, Manegold, vanKeulen, SIGMOD’09

16

[16] Изображение взято из [Boncz et al., 2008]

Cache-Conscious Соединение

Как работает [Shatdal et al., 1994], существующий Grace Hash-Join вариант:

- Оба отношения фрагментируем (по хеш-коду атрибутов соединения) на H кластеров;
- Каждый кластер помещается в L2 кеш;
- Для каждого кластера “прикладываем” элементы соответствующего фрагмента из второго отношения.

Проблемы Cache-Conscious Соединения

Часть с кластеризацией — проблемная:

- Алгоритм имеет один скан и кластеризацию, пишет в H случайных регионов (кластеров), это портит шаблон доступа к памяти;
- Если H слишком велико то:
  - записей в TLB может не хватить, будет TLB miss;
  - линеек в кеше может не хватить, будет засорение кеша и будут L1, L2 cache miss;

$\longrightarrow$ придумали radix-cluster алгоритм.

Про “железо” “на пальцах” IX: TLB

Translation Lookaside Buffer (TLB):

- Тоже “кеш-память”, встроена в CPU, обеспечивает работу виртуальной памяти;
- “Помнит” последние трансляции логических в физические адреса (обычно 64-96 штук);
- Адресует страницы в оперативной памяти:
  - на каждый load/store нужна одна трансляция
  - нашлась — получили адрес сразу же
  - не нашлась: TLB miss, идем в RAM смотрим в TLB таблицу (тут тоже может быть цепочка из промахов)
- При 4KB странице, 64 записи, можно встретить TLB miss при случайном доступе к структурам (хеш-таблицам, например) размером больше чем 256KB.

Сейчас всё сложнее, например на Sandy Bridge отдельные TLB для разных размеров[17].

[17] https://stackoverflow.com/questions/40649655/how-is-the-size-of-tlb-in-intels-sandy-bridge-cpu-determined

Предложенное решение: radix cluster I

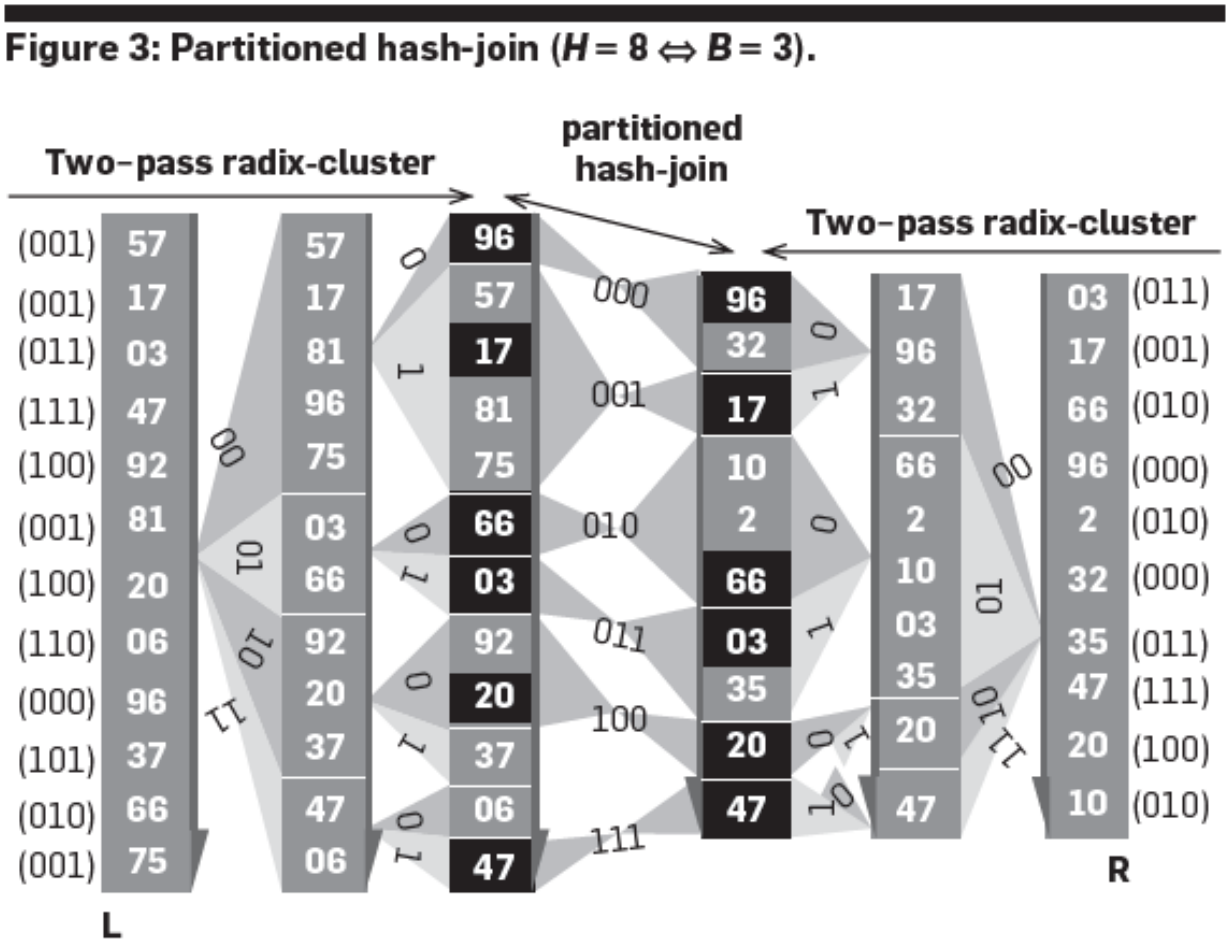

18

[18] Изображение взято из [Boncz et al., 2008]

Предложенное решение: radix cluster II

- Перестановка происходит только в рамках блока, лучше паттерн доступа, меньше вероятность промахов;
- Обычно хешируют, и работают с хеш-кодами, хотя на рисунке это не показано;
- Если колонка начинается с 0 и плотна, можно не хешировать, будет radix-sort.

Эксперименты I

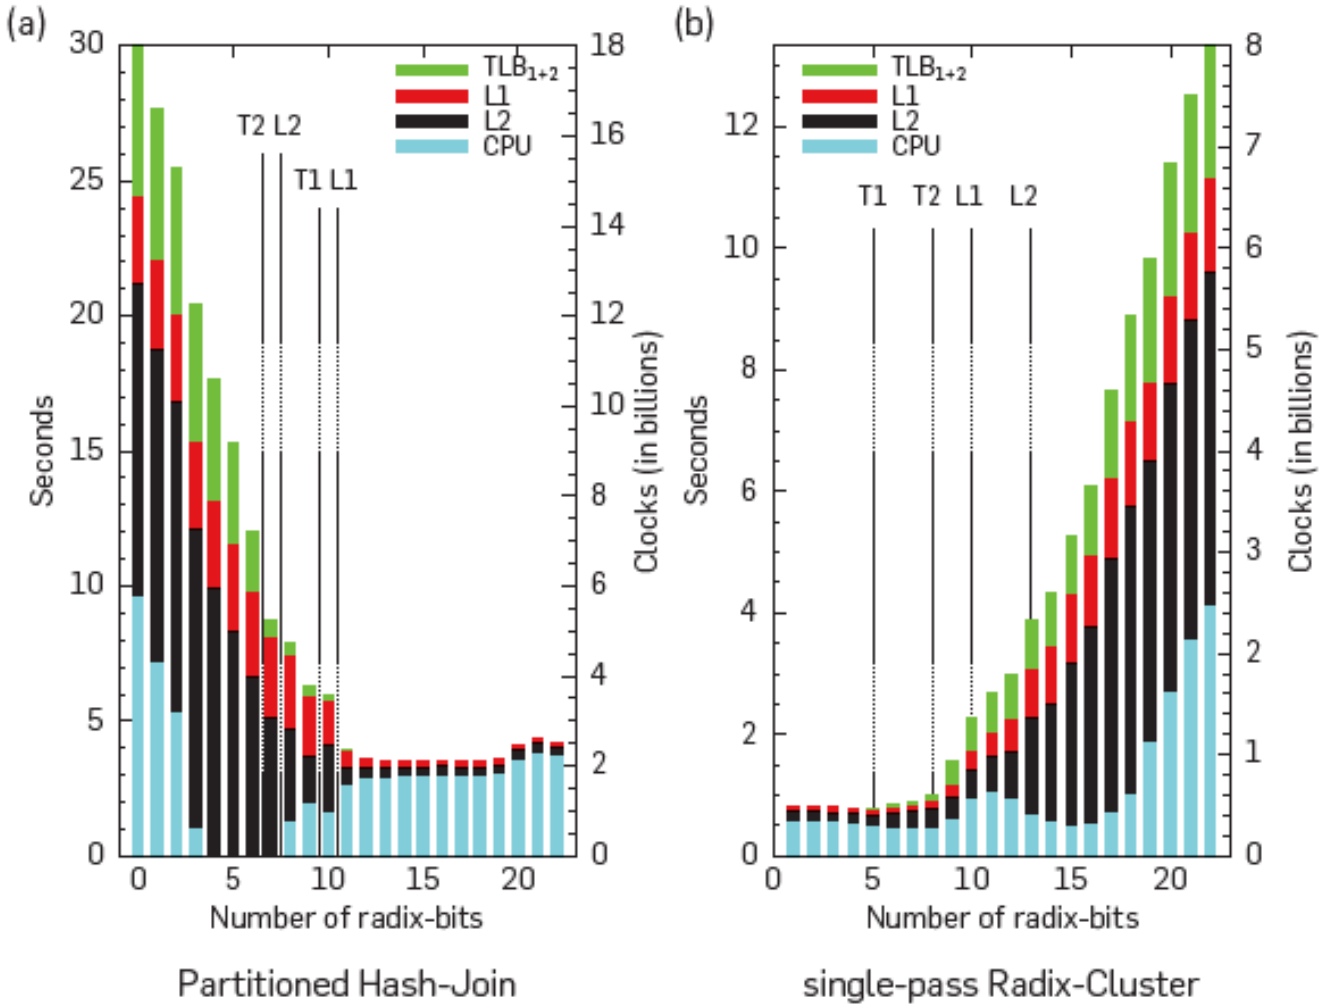

19

[19] Изображение взято из [Boncz et al., 2008]

Эксперименты II

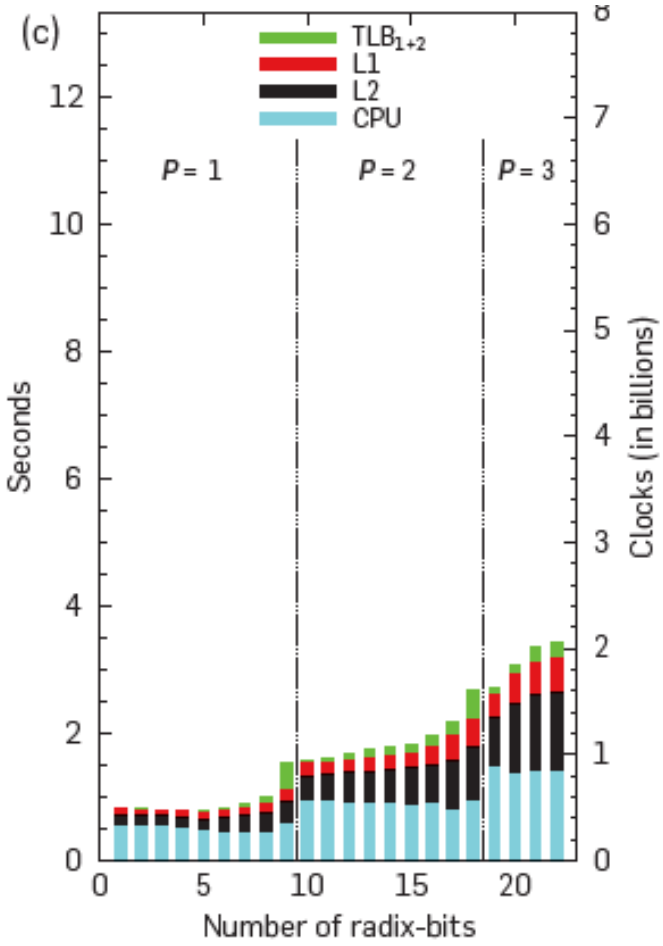

multi-pass Radix-Cluster

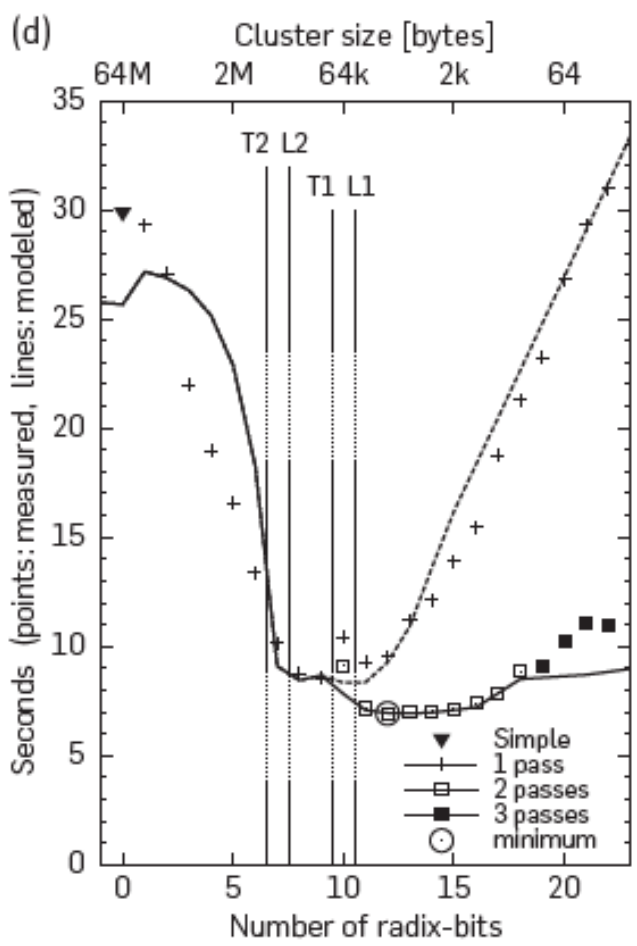

Radix-Cluster + PartHJoin

20

[20] Изображение взято из [Boncz et al., 2008]

Database Cracking: идея

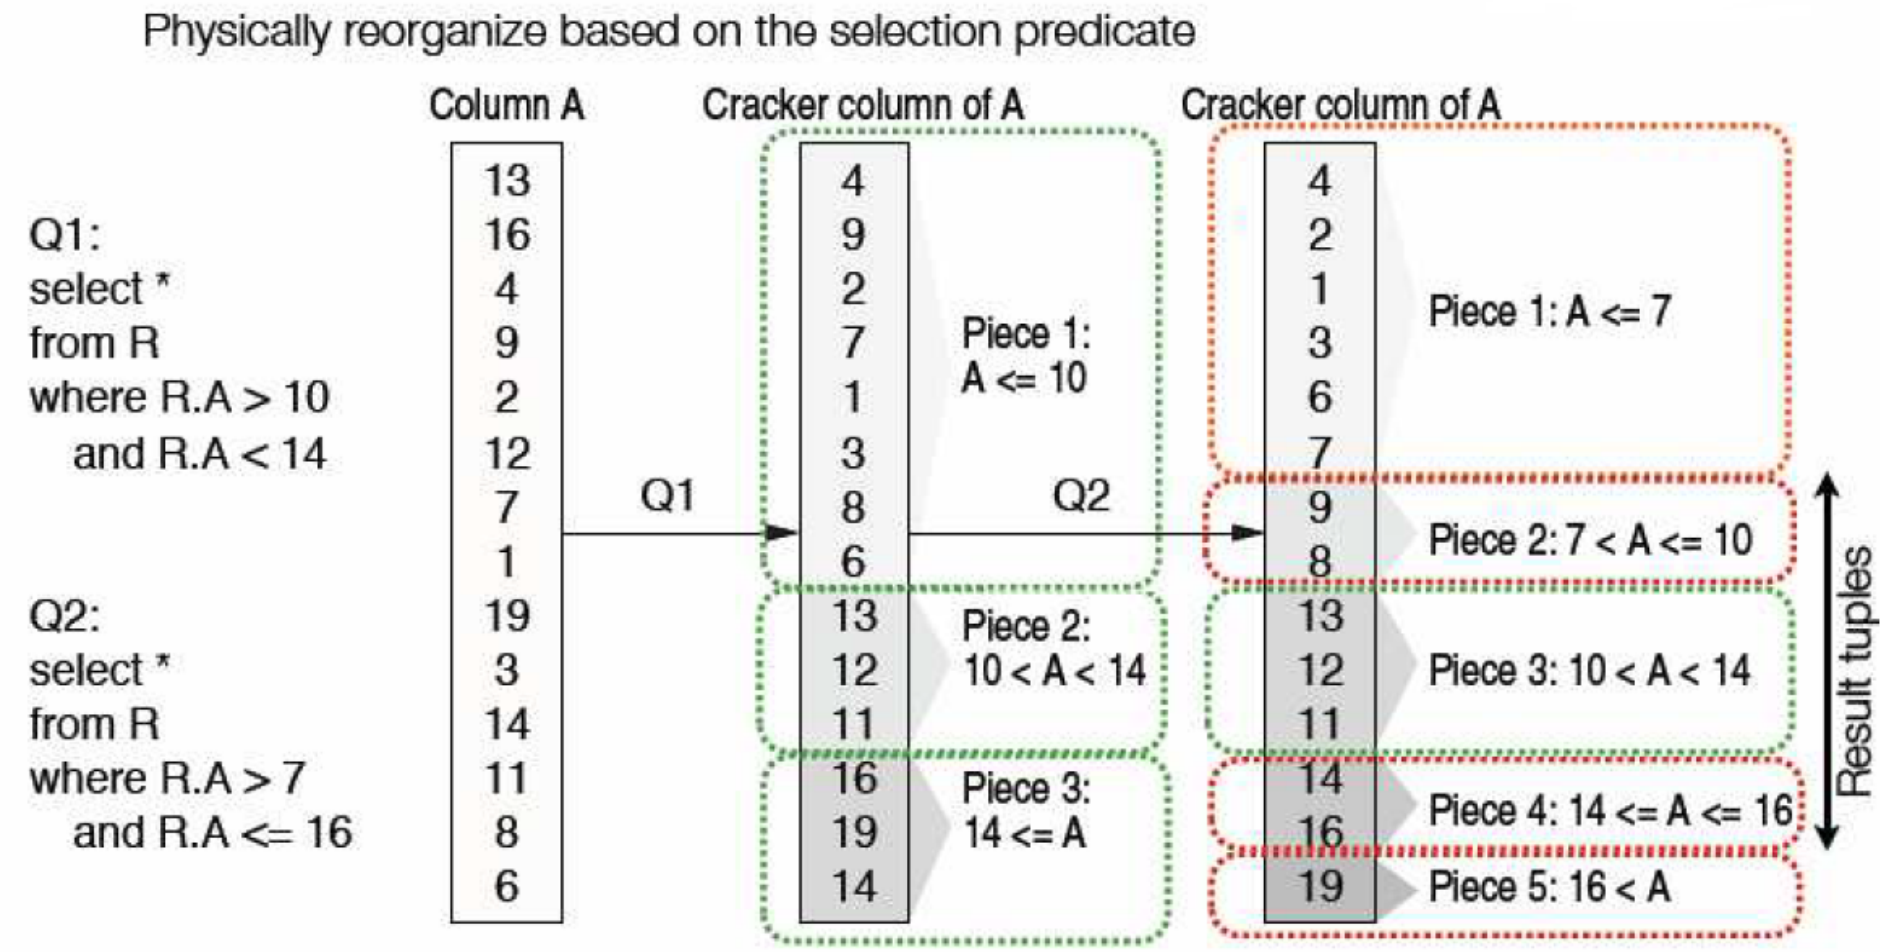

21

[21] Изображение взято из [Harizopoulos et al., 2009]

Применения Cracking

- Выше было описано как применять к колонкам при запросах на выборку (selection cracking);
- Кроме того, можно заменить восстановление записи на cracking (например, вспомните прошлую лекцию, место про соединение и нарушение порядка) — sideways cracking.

Database Cracking: эксперименты

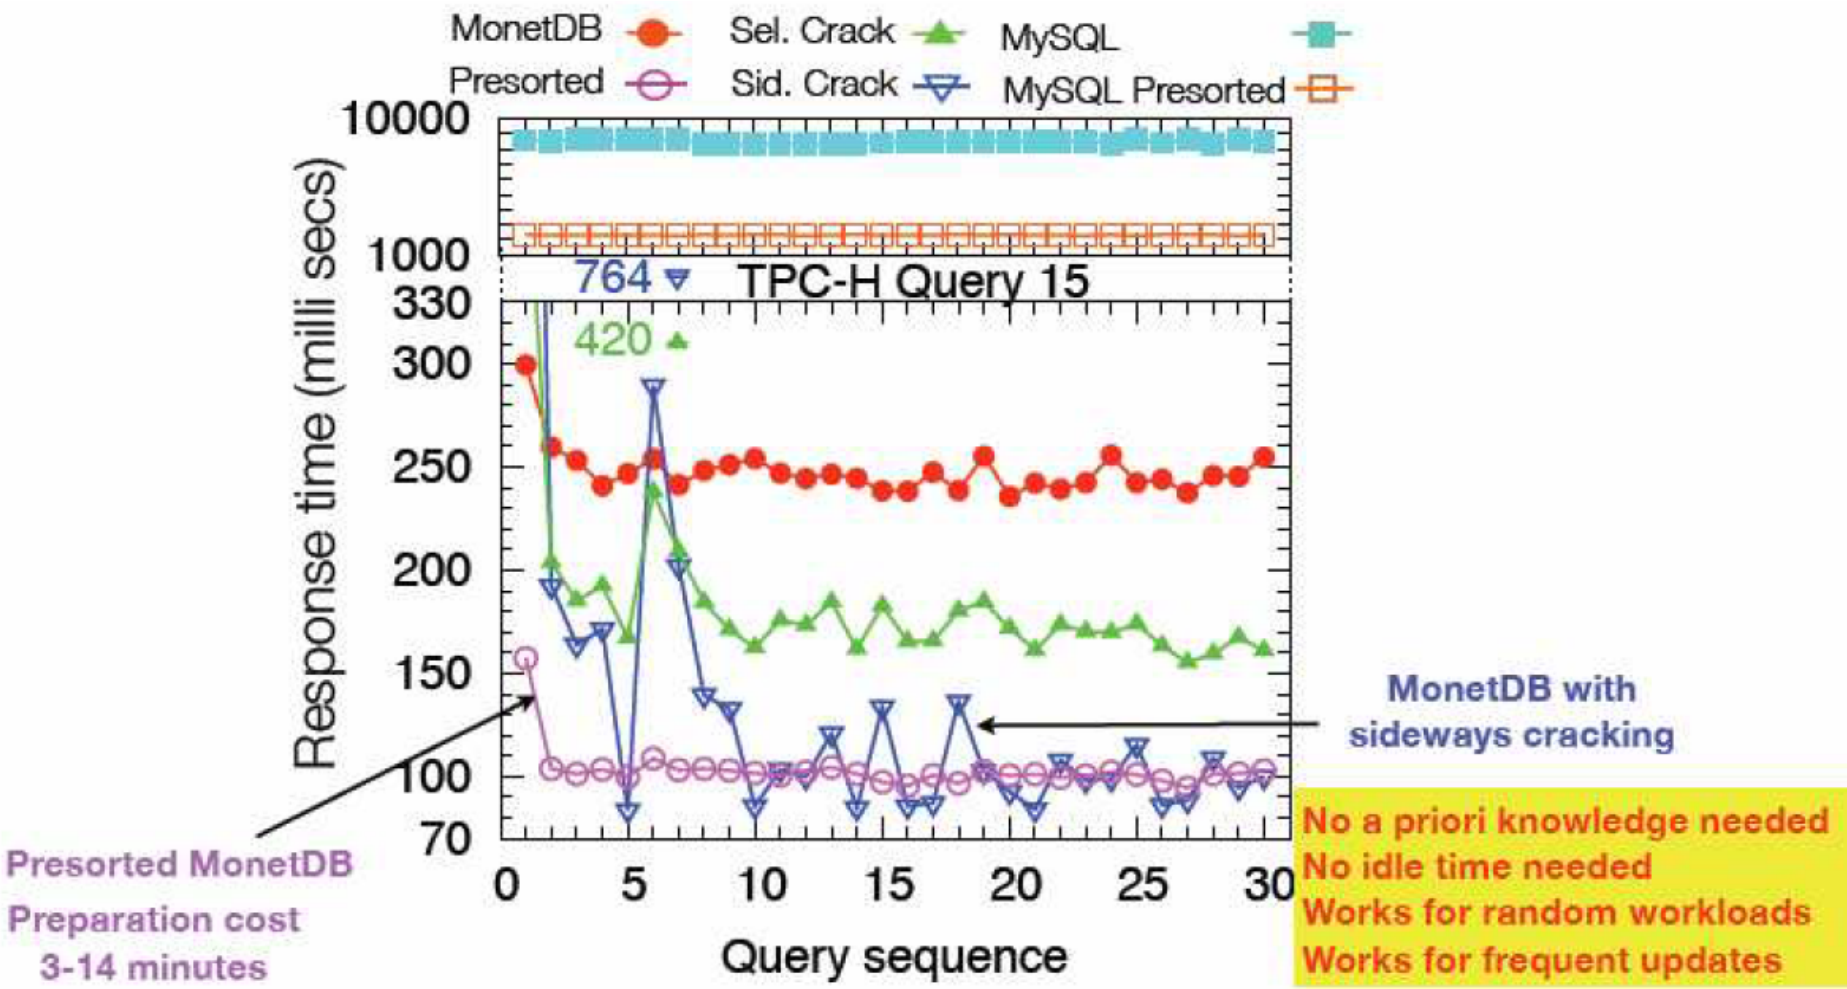

22

[22] Изображение взято из [Harizopoulos et al., 2009]

Recycler I: дерево запроса

```
function user.s1_2(A0:date,A1:date,A2:int,A3:str):void;
   X5 := sql.bind("sys","lineitem","l_returnflag",0);
   X11 := algebra.uselect(X5,A3);
   X14 := algebra.markT(X11,0@0);
   X15 := bat.reverse(X14);
   X16 := sql.bindIdxbat("sys","lineitem","li_fkey");
   X18 := algebra.join(X15,X16);
   X19 := sql.bind("sys","orders","o_orderdate",0);
   X25 := mtime.addmonths(A1,A2);
   X26 := algebra.select(X19,A0,X25,true,false);
   X30 := algebra.markT(X26,0@0);
   X31 := bat.reverse(X30);
   X32 := sql.bind("sys","orders","o_orderkey",0);
   X34 := bat.mirror(X32);
   X35 := algebra.join(X31,X34);
   X36 := bat.reverse(X35);
   X37 := algebra.join(X18,X36);
   X38 := bat.reverse(X37);
   X40 := algebra.markT(X38,0@0);
   X41 := bat.reverse(X40);
   X45 := algebra.join(X31,X32);
   X46 := algebra.join(X41,X45);
   X49 := algebra.selectNotNil(X46);
   X50 := bat.reverse(X49);
   X51 := algebra.kunique(X50);
   X52 := bat.reverse(X51);
   X53 := aggr.count(X52);
   sql.exportValue(1,"sys.orders","L1","wrd",32,0,6,X53);
end s1_2;
```

Fig. 1. MAL plan of the example query

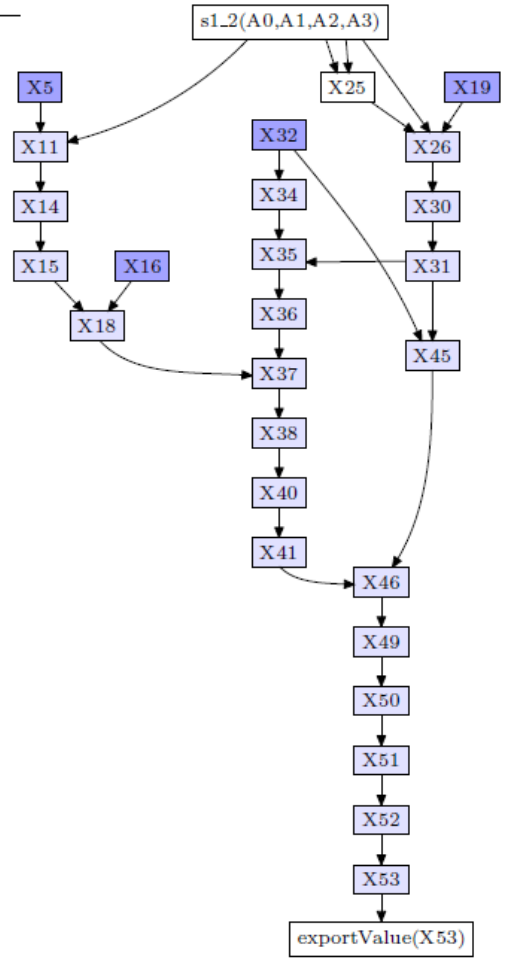

Fig. 2. Execution plan marked by the recycler optimiser [23]

[23] Изображение взято из [Ivanova et al., 2010]

Recycler II: идея

- Полная материализация промежуточных результатов — можно переиспользовать некоторые из них:
  - Локально: в рамках одного плана + в рамках шаблона;
  - Глобально: в рамках нескольких параллельно идущих запросов;
- Кеш с политикой допуска:
  - KEEPALL — храним всё;
  - CREDIT — экономические принципы;
- ...и с политикой вытеснения:
  - LRU;
  - Benefit policy;
  - History policy.

Recycler III: сколько можно сэкономить?

Query	Instructions			Time (s)			
	#	Intra %	Inter %	Total	Savings		
					Pot.	Local	Glob.
Q1	36	2.8	0	5.72	3.54	0.30	0
Q2	106	0.9	2.8	0.22	0.22	0	0.07
Q3	39	0	5.1	2.61	2.40	0	0
Q4	36	0	41.7	1.72	1.65	0	1.44
Q5	74	0	2.7	1.16	1.15	0	0
Q6	11	0	0	0.53	0.52	0	0
Q7	106	3.8	3.8	1.61	1.11	0.36	0.56
Q8	61	0	6.6	0.60	0.56	0	0.16
Q9	59	0	3.4	1.38	1.25	0	0
Q10	54	0	3.7	1.37	1.34	0	0.20
Q11	36	33.3	2.8	0.16	0.16	0.03	0
Q12	6	0	33.3	1.17	0.55	0	0
Q13	17	0	11.8	2.88	1.27	0	0
Q14	18	0	0	0.21	0.21	0	0
Q15	12	0	0	0.23	0.19	0	0
Q16	14	0	42.9	0.88	0.27	0	0.01
Q17	29	0	3.4	0.96	0.95	0	0
Q18	12	0	75.0	1.83	1.70	0	1.68
Q19	39	15.4	7.7	3.72	1.69	0.99	0.49
Q20	25	0	12.0	0.95	0.82	0	0.01
Q21	154	9.1	12.3	5.80	5.38	0.72	2.94
Q22	4	0	75.0	0.65	0.15	0	0.15

Table II. Characteristics of TCP-H queries

24

[24] Изображение взято из [Ivanova et al., 2010]

Recycler VI: тест на реальной базе

Sloan Digital Sky Servey/ SkyServer

http://cas.sdss.org

- 100 GB subset of DR4
- 100-query batch from January 2008 log
- 1.5GB intermediates, 99% reuse
- Join intermediates major consumer of memory and major contributor to savings

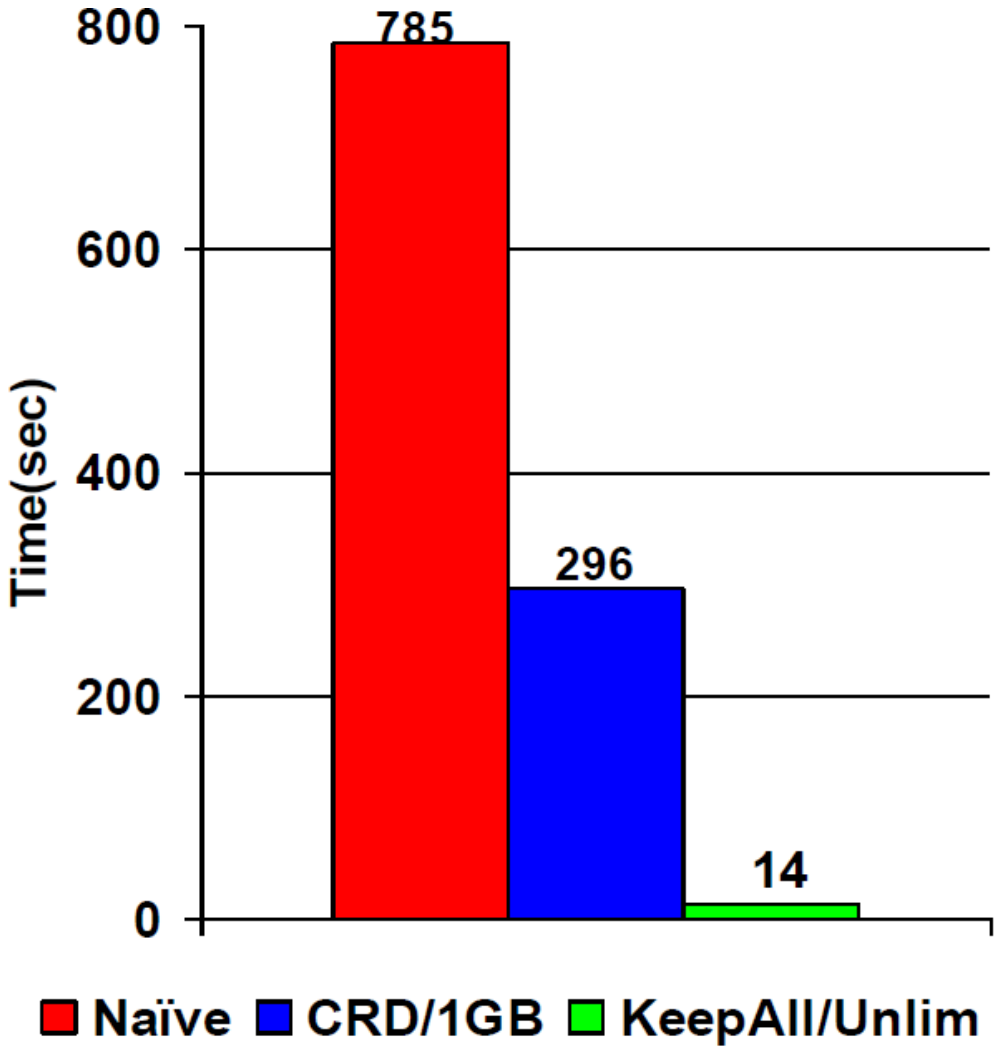

25

[25] Изображение взято из [Ivanova et al., 2010]

Данные на диске в строчных системах

В двух словах (очень приблизительно):

- Данных хранятся на диске;
- Считываются и временно хранятся в памяти;
- Обычно какой-то memory mapping;
- Менджер буферов (buffer-manager): считывание, удержание в памяти, модификация данных, сброс на диск;
  - pin/unpin;
  - алгоритм замещения: LRU, Clock algorithm, MRU, ...
- “Нарезка” на страницы: единицы оперирования менеджера буферов, 4-8 KB;
- Зачем это всё? Управление ресурсами + data sharing.

Кому интересно дальше:
`https://web.stanford.edu/class/cs346/2015/notes/Lecture_One.pdf`
Как представлять страницу? Уже обсуждали.

Напоминание: слотированная страница

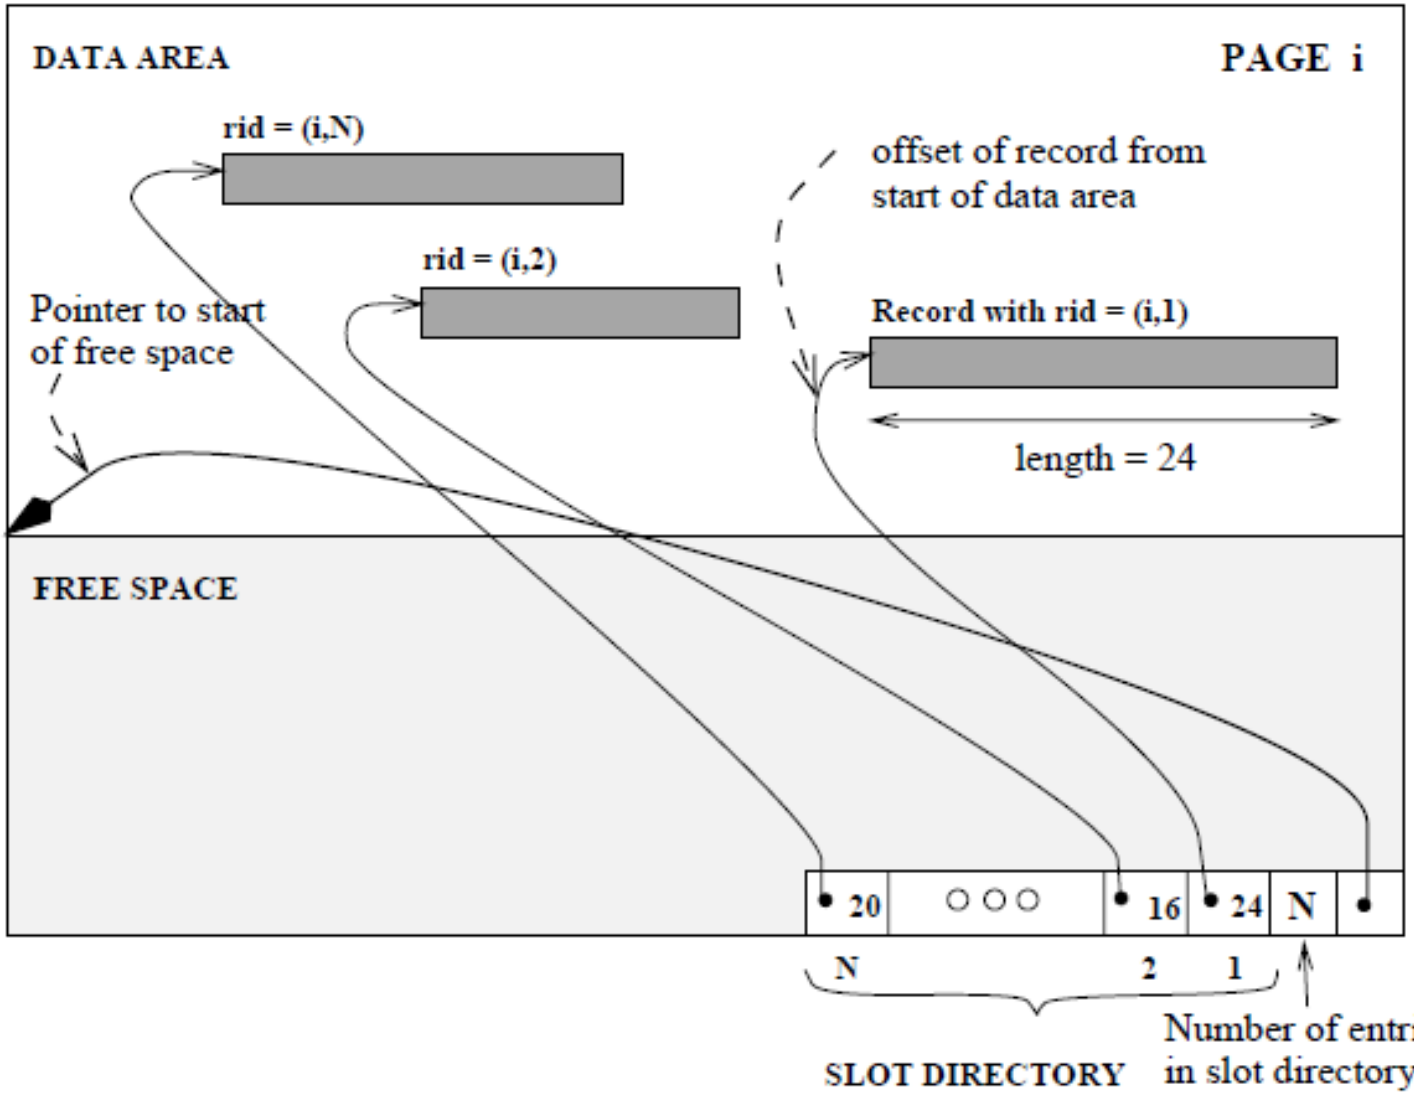

[26]

[26] Изображение взято из [Ramakrishnan and Gehrke, 2000]

MonetDB/X100 [Boncz et al., 2005]

- Избавились от полной материализации и добавили pipelining;
- Сделали “векторизацию”: в кеше массив из ста элементов;
  - Все вектора должны помещаться в кеш!
- Такие же простые операторы цикла для обработки;
- Поздняя материализация + selection vectors: col[sel[i]];

Итог: MonetDB/X100: 0.6s (слайд 16)

MonetDB/X100: архитектура

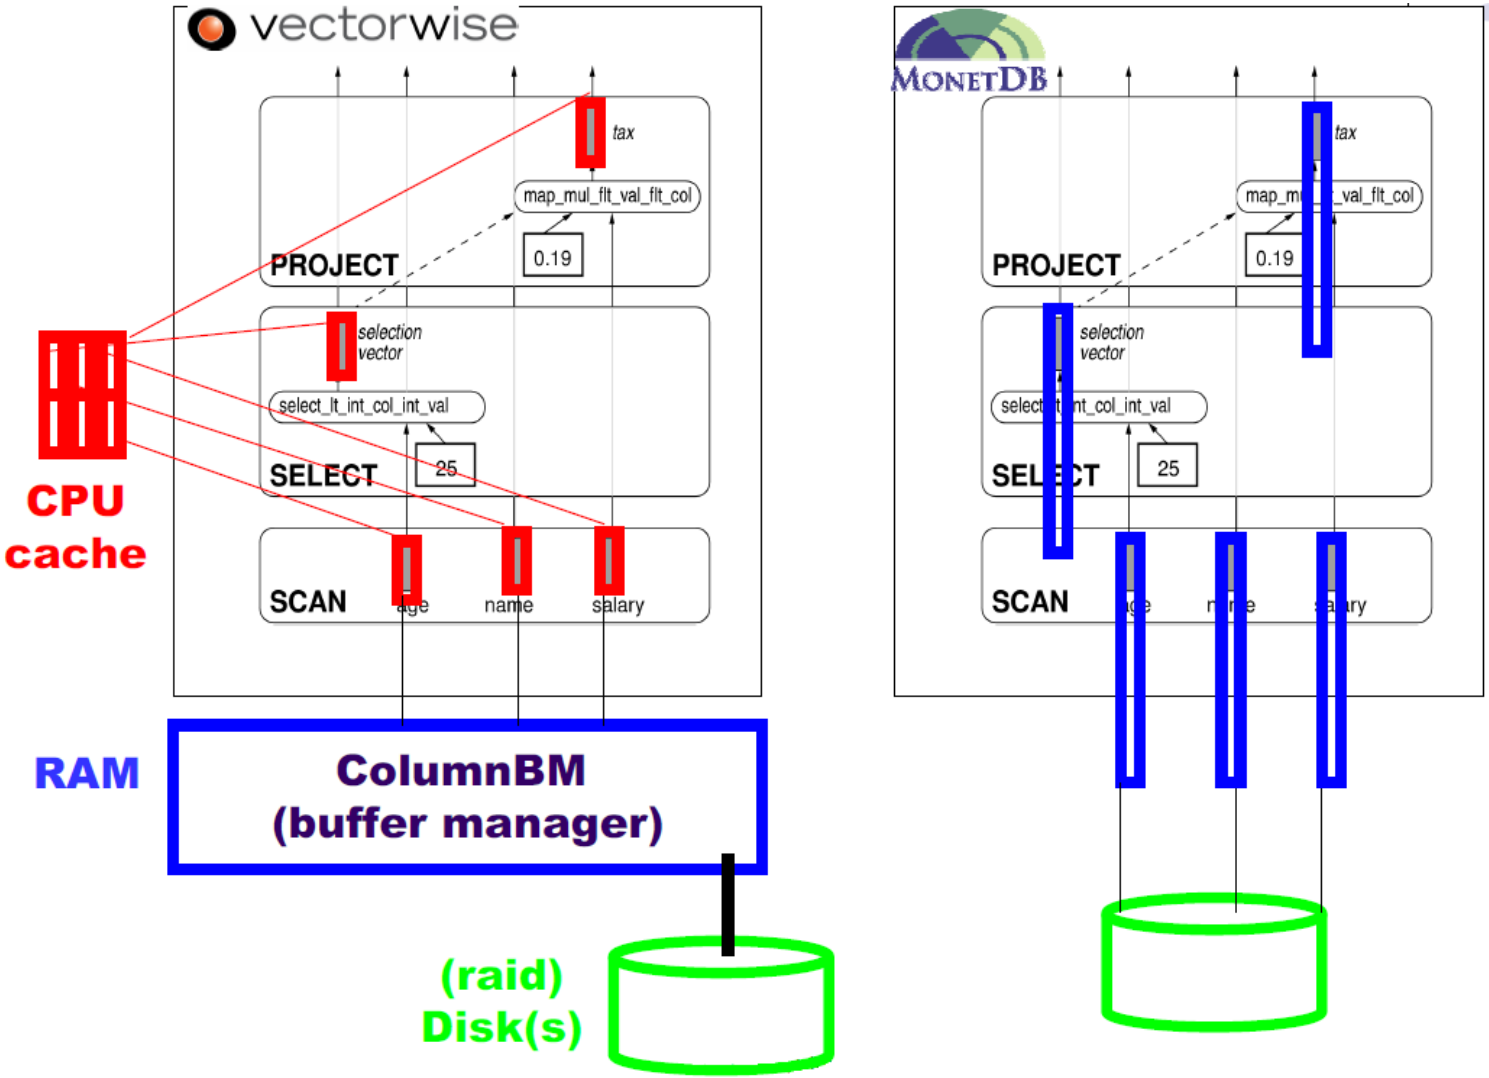

27

[27] Изображение взято из [Harizopoulos et al., 2009]

Пояснение про selection vectors

```
map_mul_flt_val_flt_col(
    float *res,
    int*   sel,
    float  val,
    float *col, int n)

{
    for(int i=0; i<n; i++)
            res[i] = val * col[sel[i]];
}
```

selection vectors used to reduce vector copying

contain selected positions

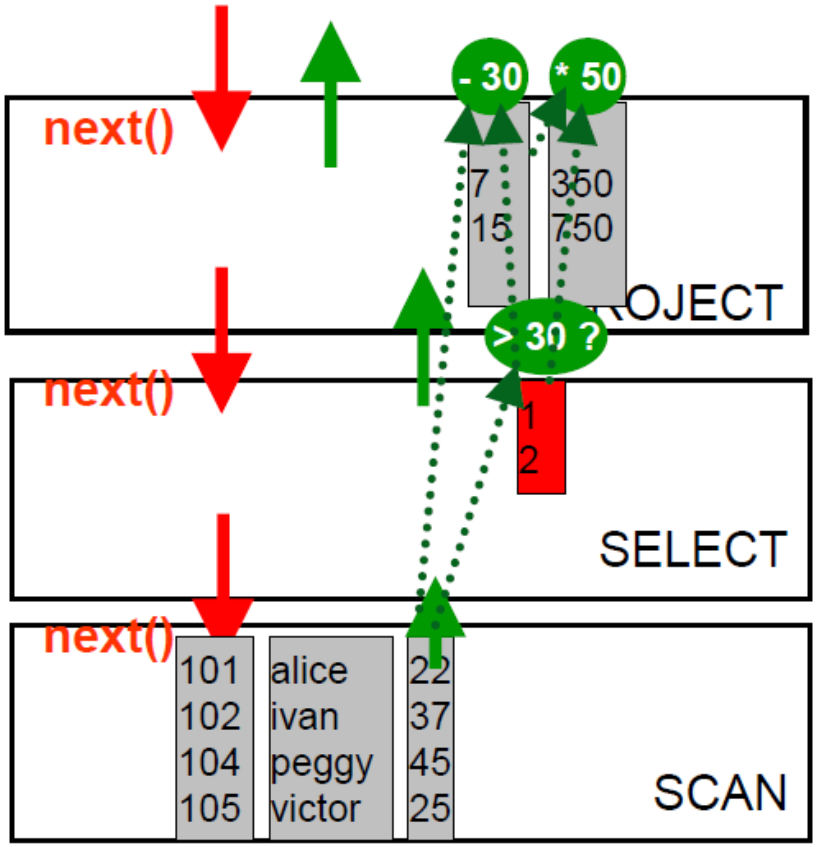

"MonetDB/X100: Hyper-Pipelining Query Execution " Boncz, Zukowski, Nes, CIDR'05

28

[28] Изображение взято из [Harizopoulos et al., 2009]

MonetDB/X100: размер вектора I

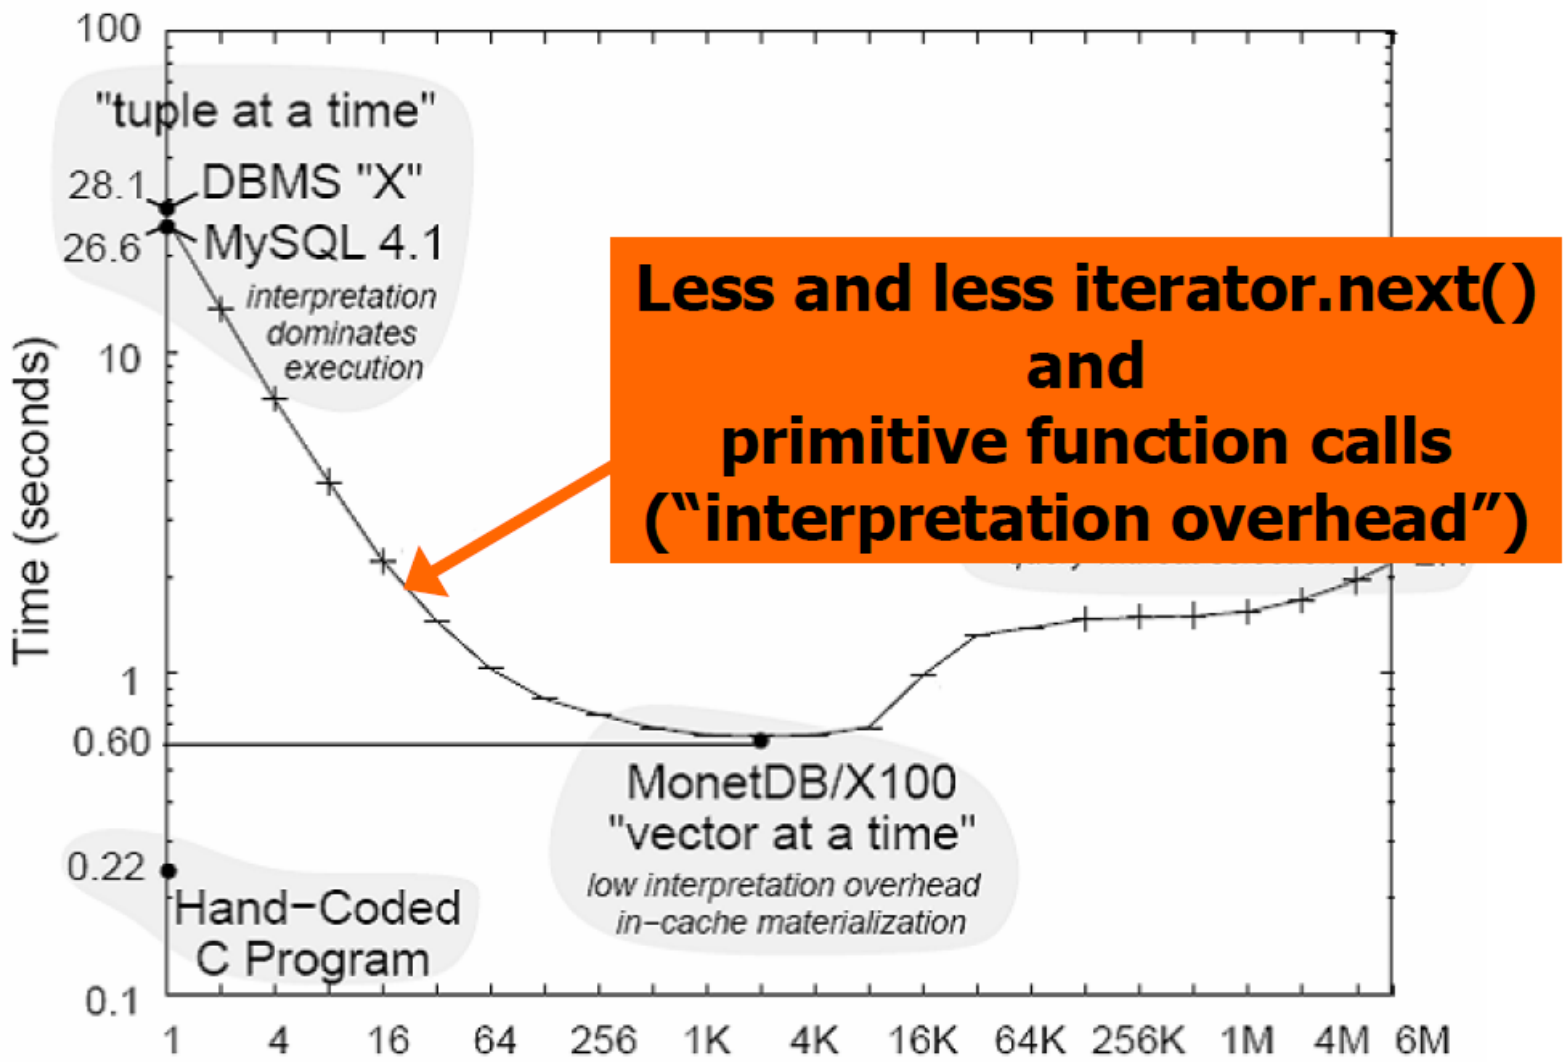

29

[29] Изображение взято из [Harizopoulos et al., 2009]

MonetDB/X100: размер вектора II

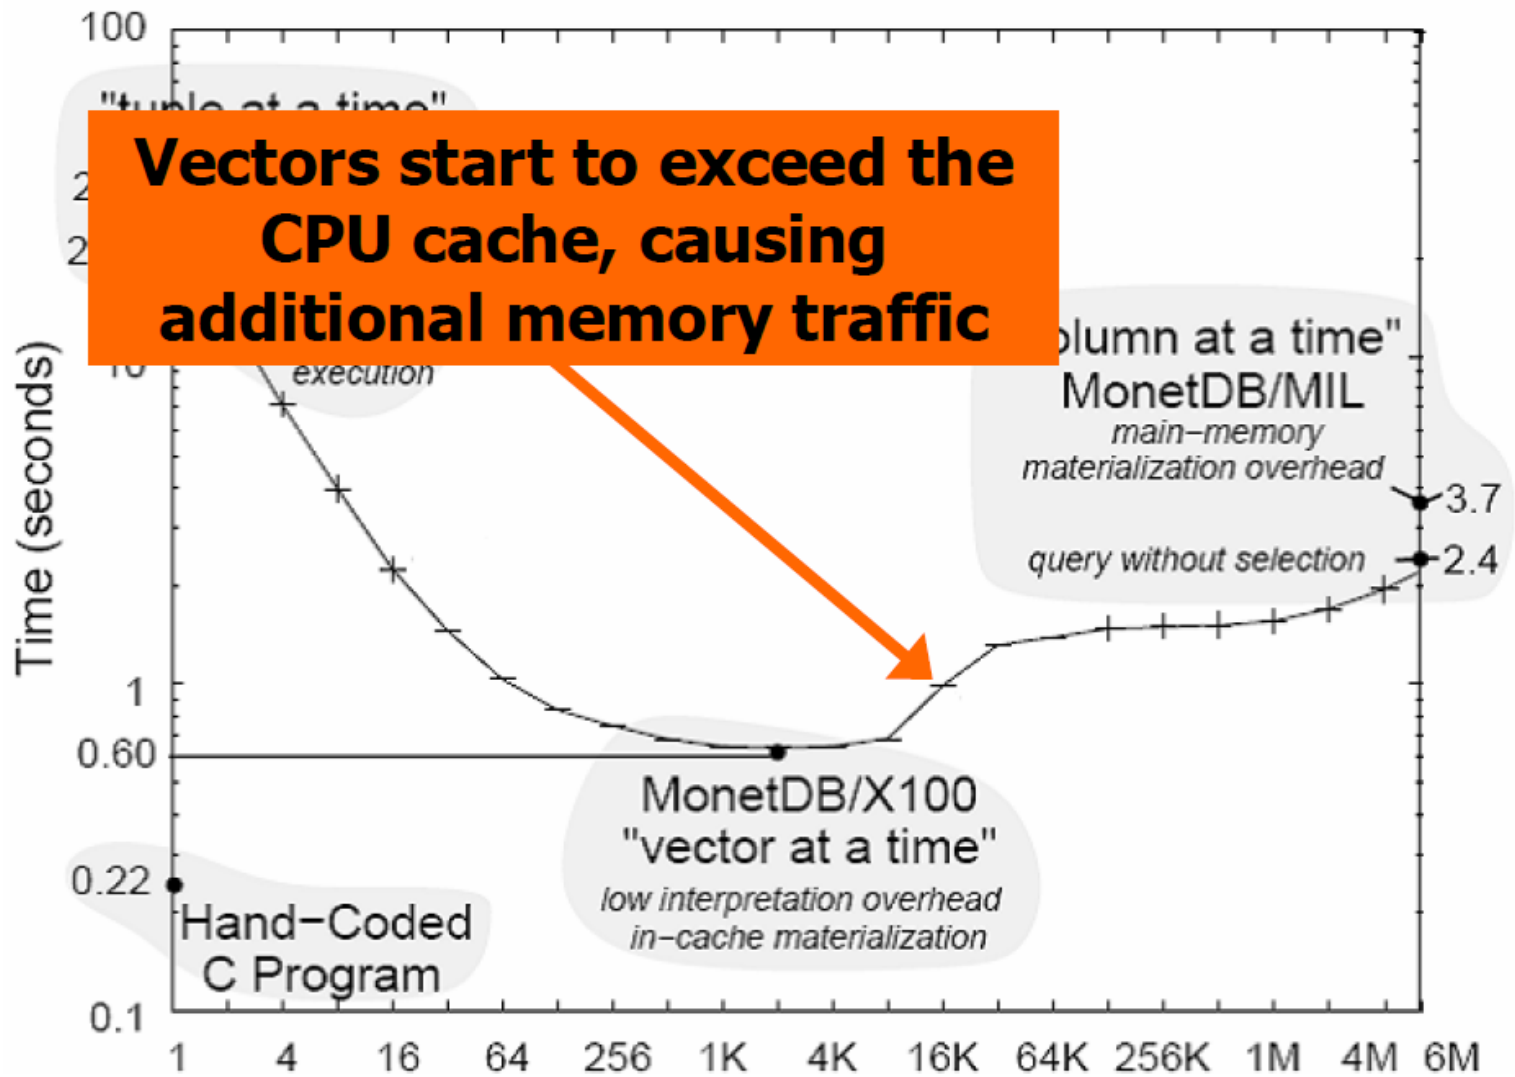

30

[30] Изображение взято из [Harizopoulos et al., 2009]

MonetDB/X100: размер вектора III

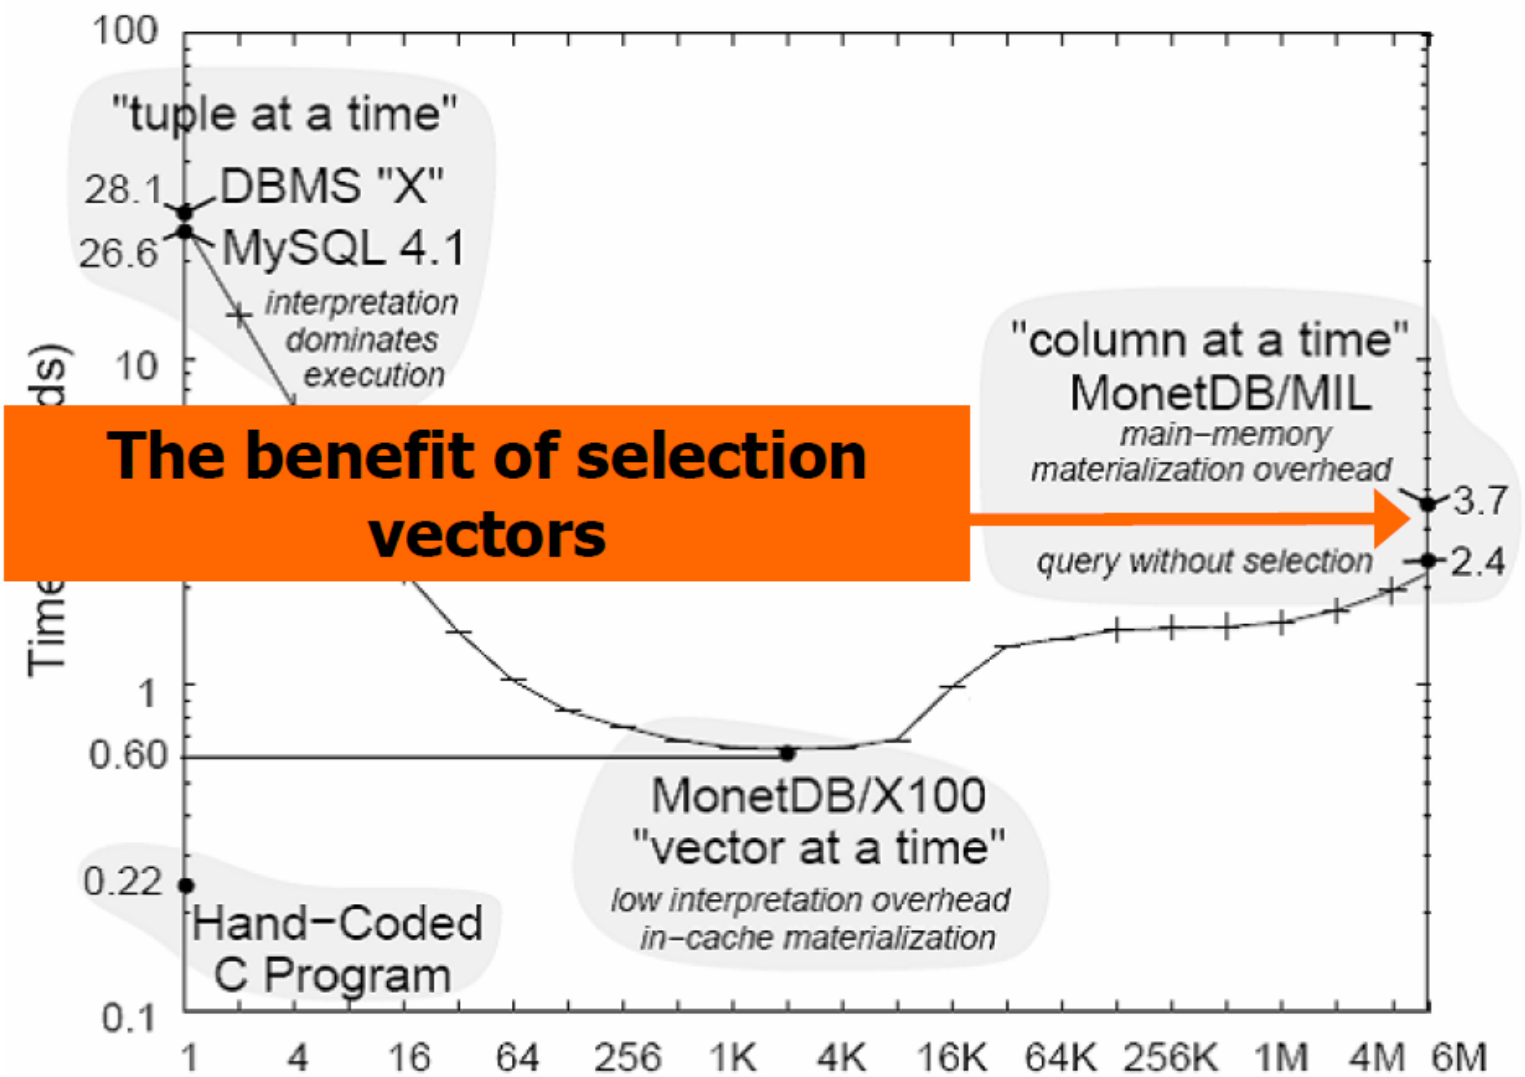

The benefit of selection vectors

31

[31] Изображение взято из [Harizopoulos et al., 2009]

Ссылки I


Milena G. Ivanova, Martin L. Kersten, Niels J. Nes, and Romulo A.P. Gonçalves. 2010. An architecture for recycling intermediates in a column-store. ACM Trans. Database Syst. 35, 4, Article 24 (October 2010), 43 pages. DOI=10.1145/1862919.1862921 http://doi.acm.org/10.1145/1862919.1862921


Ambuj Shatdal, Chander Kant, and Jeffrey F. Naughton. 1994. Cache Conscious Algorithms for Relational Query Processing. In Proceedings of the 20th International Conference on Very Large Data Bases (VLDB '94), Jorge B. Bocca, Matthias Jarke, and Carlo Zaniolo (Eds.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 510–521.


Peter A. Boncz, Martin L. Kersten, and Stefan Manegold. 2008. Breaking the memory wall in MonetDB. Commun. ACM 51, 12 (December 2008), 77–85. DOI=http://dx.doi.org/10.1145/1409360.1409380


Peter Boncz, Marcin Zukowski, Niels Nes. MonetDB/X100: Hyper-Pipelining Query Execution. CIDR'05.

Ссылки II


Peter A. Boncz and Martin L. Kersten. 1999. MIL primitives for querying a fragmented world. The VLDB Journal 8, 2 (October 1999), 101-119. DOI=http://dx.doi.org/10.1007/s007780050076


John L. Hennessy and David A. Patterson. 2011. Computer Architecture, Fifth Edition: A Quantitative Approach (5th ed.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.


Stavros Harizopoulos and Anastassia Ailamaki. 2006. Improving instruction cache performance in OLTP. ACM Trans. Database Syst. 31, 3 (September 2006), 887-920. DOI=http://dx.doi.org/10.1145/1166074.1166079


Daniel Abadi, Peter Boncz, Stavros Harizopoulos. The Design and Implementation of Modern Column-Oriented Database Systems. Foundations and Trends(R) in Databases Vol. 5, No. 3 (2012) 197–280


Stavros Harizopoulos, Daniel Abadi, Peter Boncz. Column-Oriented Database Systems. VLDB 2009 Tutorial (slides).


Raghu Ramakrishnan and Johannes Gehrke. 2000. Database Management Systems (2nd ed.). Osborne/McGraw-Hill, Berkeley, CA, USA.